deepEdu

Tutor RAG de Matemática — Ensino Médio

Documento Final de Requisitos e Conformidade

Projeto	deepEdu — Sistema RAG modular
Versão	1.0
Data	29/06/2026
Status	Aprovado para desenvolvimento
Público-alvo	Estudantes do Ensino Médio (15–17 anos)
Canal principal	WhatsApp Business Cloud API
Plataforma	Ubuntu Server · Docker · LangChain/LangGraph
Conteúdo	Requisitos · Tokens · Auditoria ECA · Revisão · Checklists · ROPA
Versão PDF	3.0 — implementação completa + casos de uso RF/RNF

Sumário

1. Parte I — Especificação de Requisitos (RF/RNF)
2. Parte II — Orçamento de Tokens (Qwen2.5-Math 4K)
3. Parte III — Auditoria Integral (ECA Digital)
4. Parte IV — Revisão de Implementação v3.0
5. Parte V — Casos de Uso (RF e RNF)
6. Parte VI — Checklist ECA Digital
7. Parte VII — Controle de Acesso (RBAC)
8. Parte VIII — Registro de Operações (ROPA)
9. Parte IX — DPIA
10. Parte X — Segurança de Dados em Repouso
11. Parte XI — Avaliação RAG
12. Anexo A — Dataset de avaliação (50 perguntas)
13. Anexo B — Prompts do sistema

Parte I — Especificação de Requisitos

Campo	Valor
Projeto	deepEdu — Tutor RAG de Matemática para Ensino Médio
Versão do documento	1.2
Data	29/06/2026
Status	Aprovado para desenvolvimento
Público-alvo	Estudantes do Ensino Médio (15–17 anos), via WhatsApp

---

1. Introdução

1.1 Propósito

Este documento define os requisitos funcionais (RF) e não funcionais (RNF) para um sistema RAG modular de tutoria em Matemática do Ensino Médio brasileiro, com canal principal WhatsApp, painel web de controle e execução em servidor Linux local (Ubuntu) via containers Docker.

1.2 Escopo

Incluído: - Pipeline completo de ingestão, indexação, recuperação e geração - Chatbot pedagógico com memória de conversa - Integração WhatsApp Business Cloud API - Dashboard web administrativo - Conformidade com BNCC (Matemática EM), LGPD e ECA Digital (Lei 15.211/2025) - Auditoria via LangSmith

Excluído (fase inicial): - Fine-tuning de modelos - App mobile nativo - Correção automática de redações longas - Integração com LMS específico (Moodle, Google Classroom etc.)

1.3 Definições e siglas

Termo	Definição
BNCC	Base Nacional Comum Curricular — documento normativo do MEC
EM13MAT	Código de habilidade de Matemática no Ensino Médio (ex.: EM13MAT101)
ECA Digital	Lei 15.211/2025 — Estatuto Digital da Criança e do Adolescente
TIR	Tool-integrated Reasoning — raciocínio com ferramenta externa (ex.: SymPy)
RAG	Retrieval-Augmented Generation
Chunk	Fragmento de texto indexado no banco vetorial
Parent-document retrieval	Recuperação por chunk pequeno com contexto expandido do documento pai

1.4 Referências normativas

- BNCC Ensino Médio — MEC
- BNCC Matemática EM — PDF oficial
- Lei 13.709/2018 (LGPD)
- Lei 15.211/2025 (ECA Digital)
- WhatsApp Cloud API — Meta
- LangChain / LangGraph
- LangSmith

---

2. Arquitetura de referência

2.1 Módulos do sistema

ID	Módulo	Responsabilidade
M01	Channel Adapters	WhatsApp, chat web de teste
M02	Orquestrador (LangGraph)	Fluxo RAG, agente, ferramentas
M03	Serviço de Memória	Histórico por sessão, resumo
M04	Retriever Híbrido	BM25 + denso + re-ranking
M05	Gerador (LLM + TIR)	Qwen2.5-Math + SymPy
M06	Pipeline de Ingestão	Loaders, limpeza, chunking, OCR
M07	Banco Vetorial	Chroma (teste) / Qdrant (produção)
M08	Metadados BNCC	PostgreSQL ou equivalente
M09	Governança	LangSmith, auditoria, LGPD
M10	Dashboard Web	Controle, métricas, gestão de corpus

2.2 Contratos de interface (modularidade — RNF09)

Cada módulo expõe interface substituível:

```
IngestionProvider      → carrega e normaliza documentos
VectorStoreProvider    → indexa e consulta vetores (Chroma/Qdrant)
RetrieverProvider      → retrieval denso/esparsa/híbrida
LLMProvider            → geração e TIR
ChannelAdapter         → entrada/saída por canal (WhatsApp, Web)
MemoryStore            → persistência de sessão
```

2.3 Fases de entrega

Fase	Escopo	Critério de conclusão
F1 — MVP local	Ingestão, RAG, chat web, LangSmith	10 perguntas de referência respondidas com citação
F2 — WhatsApp piloto	Webhook, fila, memória, consentimento	Mensagem real processada end-to-end
F3 — Produção escolar	Qdrant, dashboard, BNCC, ECA Digital	Checklist de conformidade 100% nos itens obrigatórios

---

3. Requisitos funcionais

RF01 — Chatbot pedagógico coloquial

Descrição: O sistema deve responder consultas em linguagem coloquial e acessível a adolescentes (15–17 anos), mantendo rigor matemático.

Módulos: M02, M05, M01

Critérios de aceitação: - [ ] Respostas em português brasileiro, tom de tutor (não robótico) - [ ] Evita jargão não explicado; define termos na primeira ocorrência - [ ] Em 90% de um conjunto de 20 perguntas piloto, avaliadores classificam tom como “adequado ao EM”

RF02 — Configuração do ecossistema LangChain

Descrição: Utilizar LangChain como base de composição de componentes (loaders, retrievers, chains/runnables).

Módulos: M02, M04, M05, M06

Critérios de aceitação: - [ ] Dependências LangChain versionadas em `requirements.txt` ou equivalente - [ ] Componentes compostos via LCEL (`|` pipe) onde aplicável - [ ] Documentação de versões mínimas no README do projeto

---

RF03 — Memória de conversa multi-turno

Descrição: Manter contexto entre mensagens da mesma sessão para conversas com múltiplas trocas.

Módulos: M03, M02

Critérios de aceitação: - [ ] Sessão identificada por `session_id` (WhatsApp: número + thread; Web: UUID) - [ ] Pergunta de follow-up (“e no caso da função quadrática?”) usa histórico sem repetir contexto inteiro - [ ] Memória persiste entre reinícios do container (volume ou banco)

RF04 — Orquestração com LangGraph

Descrição: Orquestrar o fluxo conversacional com LangGraph e checkpointer (substitui `ConversationChain`, depreciado).

Módulos: M02

Critérios de aceitação: - [ ] Grafo definido com nós: `retrieve` → `generate` → (opcional) `verify` → `respond` - [ ] Checkpointer configurado (SQLite, PostgreSQL ou Redis) - [ ] Suporte a `stream` e `ainvoke` para respostas assíncronas - [ ] Não utiliza `ConversationChain` em código de produção

---

RF05 — Interface web de chat (teste e admin)

Descrição: Interface web simples para interação com o chatbot e testes internos.

Módulos: M01, M10

Critérios de aceitação: - [ ] Campo de entrada de mensagem e histórico visível - [ ] Exibe fontes citadas (RF29) - [ ] Acessível apenas com autenticação (RNF14) - [ ] Renderiza fórmulas LaTeX via MathJax ou KaTeX (RF34)

RF06 — Prompts personalizados para Matemática EM

Descrição: Prompts de sistema versionados para tutoria em Matemática do Ensino Médio.

Módulos: M02, M05

Critérios de aceitação: - [ ] Arquivo(s) de prompt em `prompts/` com versionamento (ex.: `v1_tutor_em.md`) - [ ] Prompt inclui: persona de tutor, idioma PT-BR, pedido de passos, proibição de inventar fontes - [ ] Prompt distingue modo tutor (padrão) e modo avaliação (RF44) - [ ] Alteração de prompt não exige mudança de código (apenas config/arquivo) - [ ] **Prompt de sistema ≤ 400 tokens** (tokenizer Qwen2.5-Math) — ver `docs/TOKEN_BUDGET.md` - [ ] Prompt instrui respostas concisas (economia de tokens para janela 4K)

RF07 — Consciência de contexto em conversas

Descrição: Utilizar histórico, intenção e entidades para respostas contextualizadas.

Módulos: M02, M03

Critérios de aceitação: - [ ] Referência a mensagens anteriores da sessão em respostas coerentes - [ ] Extração de entidades matemáticas (tema, função, equação) registrada no estado do grafo - [ ] Teste: sequência de 3 mensagens sobre o mesmo problema mantém coerência

---

RF08 — Gestão otimizada de memória

Descrição: Combinar memória de buffer e resumo; limitar detalhes desnecessários.

Módulos: M03

Critérios de aceitação: - [ ] Janela de buffer configurável (padrão: últimas 4 trocas) - [ ] Resumo automático quando histórico excede **600 tokens** (`HISTORY_SUMMARY_TRIGGER`) - [ ] Histórico (buffer + resumo) **≤ 800 tokens** no prompt final - [ ] Resumo preserva: tema matemático, dados do problema, passos já explicados - [ ] Entrada incompleta ou ambígua gera pergunta de esclarecimento (não resposta inventada) - [ ] Contagem de tokens com tokenizer Qwen (não estimativa por caracteres)

RF09 — Decomposição de consultas e ferramentas externas

Descrição: Decompor consultas complexas em subtarefas; usar ferramentas (APIs, calculadora, SymPy).

Módulos: M02, M05

Critérios de aceitação: - [ ] Agente com nó `plan` para perguntas multi-etapa (ex.: “explique e calcule a derivada de x²+3x”) - [ ] Ferramenta `sympy_calculate` disponível ao agente - [ ] Ferramenta `search_knowledge_base` disponível ao agente - [ ] Resultados das ferramentas integrados na resposta final (RF10)

RF10 — Síntese coerente de respostas

Descrição: Integrar resultados de retrieval e ferramentas numa resposta única e coerente.

Módulos: M02, M05

Critérios de aceitação: - [ ] Resposta final não expõe JSON interno ou logs de ferramentas - [ ] Estrutura pedagógica: contexto → passos → conclusão - [ ] Sem contradição entre trechos recuperados e cálculo via SymPy

---

RF11 — Armazenamento e atualização dinâmica de contexto

Descrição: Armazenar entradas, intenções e entidades; atualizar com novas mensagens.

Módulos: M03, M02

Critérios de aceitação: - [ ] Estado da sessão inclui: `messages`, `intent`, `entities`, `bncc_tags` (quando identificados) - [ ] Nova mensagem atualiza estado antes da geração - [ ] Contexto recuperado do RAG é separado do histórico conversacional

---

RF12 — Arquitetura RAG (componentes obrigatórios)

Descrição: O sistema deve implementar Retriever, Gerador, Fonte de conhecimento e Orquestrador.

Módulos: M04, M05, M06, M07, M02

Critérios de aceitação: - [ ] Cada componente em módulo/pacote separado com interface definida - [ ] Orquestrador conecta retriever → gerador em fluxo contínuo - [ ] Fonte de conhecimento consultável independentemente do canal (WhatsApp/Web)

RF13 — Recuperação híbrida (denso + esparso)

Descrição: Combinar busca densa (embeddings) e esparsa (BM25) com fusão de resultados.

Módulos: M04

Critérios de aceitação: - [ ] Implementação BM25 (ex.: `rank_bm25` ou índice OpenSearch/Elasticsearch) - [ ] Implementação densa via banco vetorial (M07) - [ ] Fusão por Reciprocal Rank Fusion (RRF) ou equivalente documentado - [ ] Parâmetro `top_k` configurável por ambiente - [ ] Em benchmark interno de 30 perguntas, híbrido ≥ denso isolado em precisão@5

RF14 — Gerador com modelo de domínio matemático

Descrição: Utilizar modelo especializado em matemática, não LLM genérico.

Módulos: M05

Critérios de aceitação: - [ ] Modelo: `Qwen2.5-Math-1.5B-Instruct` (ou versão superior aprovada) - [ ] Janela de contexto: **4.096 tokens** (`max_position_embeddings` — série Math, não 128K) - [ ] Inferência local via Ollama, vLLM ou transformers - [ ] `LLM_MAX_NEW_TOKENS=1024`, `LLM_TEMPERATURE=0.3` (documentado em `.env.example`) - [ ] Montagem de prompt respeita orçamento em `docs/TOKEN_BUDGET.md` - [ ] Fallback documentado se modelo indisponível (degradação graceful)

RF15 — Fontes de conhecimento estruturadas e não estruturadas

Descrição: Suportar PDFs, DOCX, TXT e fontes estruturadas com metadados.

Módulos: M06, M07, M08

Critérios de aceitação: - [ ] Loaders: PyPDFLoader, TextLoader, UnstructuredWordDocumentLoader (ou equivalente) - [ ] Fonte estruturada: tabela/arquivo com mapeamento BNCC (CSV, JSON ou PostgreSQL) - [ ] Cada documento indexado com metadados mínimos (RF36) - [ ] Web em tempo real **não** é fonte primária; apenas whitelist opcional (RF19)

RF16 — Pipeline de ingestão em lote

Descrição: Carregar e processar documentos em lotes para evitar esgotamento de memória.

Módulos: M06

Critérios de aceitação: - [ ] Parâmetro `batch_size` configurável (padrão: 32–64 documentos) - [ ] Script CLI `run_indexing.py` (ou equivalente) processa diretório inteiro - [ ] Log de progresso: documentos processados / total / erros - [ ] Falha em um documento não interrompe o lote inteiro

---

RF17 — Limpeza e normalização de texto

Descrição: Remover ruído, normalizar texto e eliminar duplicados antes da indexação.

Módulos: M06

Critérios de aceitação: - [ ] Remoção de tags HTML, caracteres de controle, headers/footers repetitivos de PDF - [ ] Normalização de espaços e quebras de linha - [ ] Detecção de duplicados por hash de conteúdo (SHA-256) - [ ] Relatório pós-ingestão: docs inseridos, ignorados, duplicados

---

RF18 — Tratamento multi-formato de documentos

Descrição: Suportar texto, PDF nativo, DOCX; OCR para PDFs escaneados.

Módulos: M06

Critérios de aceitação: - [ ] PDF com texto selecionável: extração via PyPDFLoader ou pdfplumber - [ ] PDF escaneado: OCR via Tesseract ou docTR com flag `--ocr` - [ ] DOCX: extração de parágrafos e tabelas - [ ] Formatos não suportados geram log de aviso, não crash

---

RF19 — Web controlada (opcional)

Descrição: Permitir ingestão web apenas de domínios na whitelist, com revisão.

Módulos: M06

Critérios de aceitação: - [ ] Lista de domínios permitidos em configuração - [ ] WebBaseLoader desabilitado por padrão - [ ] Conteúdo web passa pelas mesmas etapas de limpeza (RF17) antes de indexar

---

RF20 — Fragmentação (chunking) semântica

Descrição: Segmentar por frases e parágrafos, preservando blocos matemáticos.

Módulos: M06

Critérios de aceitação: - [ ] Separadores: `\n\n`, `.`, com exceção para blocos LaTeX (`$...$`, `$$...$$`) - [ ] Chunk não corta equação ao meio - [ ] Estratégia documentada no README técnico

---

RF21 — Chunks granulares com parent-document retrieval

Descrição: Chunks pequenos para busca precisa; contexto expandido do documento pai na geração.

Módulos: M04, M06

Critérios de aceitação: - [ ] Tamanho alvo do chunk filho: 300–400 tokens (configurável) - [ ] Chunk injetado no prompt (parent truncado): **máx. 400 tokens** cada - [ ] Total de contexto RAG no prompt: **máx. 1.200 tokens** (`top_k=3` padrão) - [ ] Retriever retorna chunk filho; gerador recebe parent truncado ao orçamento - [ ] Truncagem por fim de parágrafo, nunca no meio de equação

---

RF22 — Geração de embeddings

Descrição: Incorporar texto com modelo multilíngue compatível com português.

Módulos: M06, M07

Critérios de aceitação: - [ ] Modelo padrão: `intfloat/multilingual-e5-base` (Hugging Face) ou equivalente aprovado - [ ] Alternativa OpenAI documentada em configuração - [ ] Dimensão do vetor registrada nos metadados do índice - [ ] Embeddings gerados em lote (RF23)

RF23 — Embeddings em lote

Descrição: Processar embeddings em batch para eficiência em grande escala.

Módulos: M06

Critérios de aceitação: - [ ] `embedding_batch_size` configurável (padrão: 64) - [ ] Tempo de indexação de 1000 chunks documentado em benchmark interno

---

RF24 — Banco de dados vetorial

Descrição: Armazenar e consultar vetores com ambientes distintos para teste e produção.

Módulos: M07

Critérios de aceitação: - [ ] Testes/desenvolvimento: **Chroma** (embutido ou client-server) - [ ] Produção: **Qdrant** (ou pgvector se PostgreSQL já existir — decisão documentada em ADR) - [ ] Troca de provider via configuração, sem alterar lógica de negócio (RNF09) - [ ] Coleção/index com nome e versão (ex.: `matematica_em_v1`)

RF25 — Similaridade por cosseno

Descrição: Usar similaridade cosseno na busca densa.

Módulos: M04, M07

Critérios de aceitação: - [ ] Métrica configurada como `cosine` no banco vetorial - [ ] Score de similaridade retornado e registrado no LangSmith

---

RF26 — Re-ranking pós-recuperação

Descrição: Aplicar re-ranking para melhorar precisão após fusão híbrida.

Módulos: M04

Critérios de aceitação: - [ ] Cross-encoder ou LLM-reranker aplicado aos top-N candidatos (N ≥ 20, retorno top 5) - [ ] Re-ranking configurável (on/off) por ambiente - [ ] Latência adicional documentada (p95)

RF27 — Filtragem de conteúdo sensível na indexação

Descrição: Detectar e mascarar dados confidenciais antes da indexação.

Módulos: M06, M09

Critérios de aceitação: - [ ] Regex/heurísticas para: CPF, e-mail, telefone, “senha”, “cartão” - [ ] Substituição por `[REDACTED]` antes de persistir - [ ] Log de redações sem expor valor original

---

RF28 — Mitigação de viés

Descrição: Reduzir respostas tendenciosas ou estereotipadas.

Módulos: M02, M05

Critérios de aceitação: - [ ] Prompt instrui inclusão de perspectivas diversas quando aplicável - [ ] Corpus de indexação documentado quanto à diversidade de fontes - [ ] Revisão manual trimestral de 20 respostas aleatórias (procedimento documentado)

RF29 — Transparência: citação de fontes

Descrição: Apresentar documentos/chunks usados na geração da resposta.

Módulos: M02, M01, M10

Critérios de aceitação: - [ ] Cada resposta inclui: `documento`, `página` (se disponível), `chunk_id`, `habilidade_bncc` (se mapeada) - [ ] WhatsApp: citação em texto compacto (ex.: “Fonte: Apostila Funções, p.12”) - [ ] Web: citação com link para visualização do chunk no dashboard - [ ] Resposta sem chunk recuperado aciona RF38 (abstinência)

RF30 — Privacidade e conformidade LGPD

Descrição: Anonimização, auditoria, consentimento e direitos do titular.

Módulos: M09

Critérios de aceitação: - [ ] PII removida/mascarada antes de indexação (RF27) - [ ] Registro de auditoria: `timestamp`, `session_id` pseudonimizado, `action`, `resource` - [ ] Endpoint/procedimento para exclusão de dados da sessão por solicitação - [ ] Política de retenção configurável (padrão: 90 dias para histórico de chat) - [ ] ROPA (registro de operações de tratamento) documentado em `docs/ROPA.md`

RF31 — Auditoria via LangSmith

Descrição: Rastrear todas as execuções do pipeline RAG no LangSmith.

Módulos: M09, M02

Critérios de aceitação: - [ ] `LANGCHAIN_TRACING_V2=true` em produção - [ ] Tags por execução: `session_id`, `channel`, `bncc_skill` (quando aplicável) - [ ] Traces incluem: query, chunks recuperados, scores, prompt, resposta, latência - [ ] Projeto LangSmith separado por ambiente (dev/staging/prod)

RF32 — Conformidade ECA Digital (Lei 15.211/2025)

Descrição: Atender obrigações para sistemas com acesso provável por menores.

Módulos: M09, M01

Critérios de aceitação: - [ ] Inventário do ecossistema digital documentado (`docs/ECA_DIGITAL_CHECKLIST.md`) - [ ] Arquitetura de auditoria implementada conforme `docs/AUDITORIA_ECA.md` - [ ] Consentimento parental granular, não genérico (RF42) - [ ] Verificação de faixa etária sem autodeclaração simples (vínculo com matrícula ou código escolar) - [ ] DPIA (Relatório de Impacto) preenchido antes de produção - [ ] Cláusulas contratuais com escola: exclusão de dados, notificação de incidentes em 24h - [ ] Proibição de uso de dados de alunos para publicidade ou perfilamento - [ ] **Todo módulo** (M01–M10) emite eventos auditáveis (RF47)

RF33 — Alinhamento BNCC — Matemática Ensino Médio

Descrição: Respostas e conteúdo indexado alinhados às competências e habilidades EM13MAT.

Módulos: M08, M02, M05

Critérios de aceitação: - [ ] Base normativa: documento oficial MEC (não apenas plataformas auxiliares) - [ ] Metadados incluem código de habilidade quando identificável (ex.: EM13MAT305) - [ ] Resposta referencia competência/habilidade quando pertinente - [ ] Catálogo de habilidades carregado em M08 a partir do PDF/CSV oficial - [ ] bncc.digital pode ser fonte auxiliar de planos, não norma legal

---

RF34 — Notação matemática (LaTeX)

Descrição: Suportar fórmulas e símbolos matemáticos na geração e exibição.

Módulos: M05, M01, M10

Critérios de aceitação: - [ ] LLM gera fórmulas em LaTeX inline (`$...$`) e display (`$$...$$`) - [ ] Dashboard renderiza com MathJax ou KaTeX - [ ] WhatsApp: fallback para notação linear legível (ex.: `x^2 + 3x`) quando LaTeX não renderiza - [ ] Opcional: gerar imagem da fórmula para WhatsApp (fase F3)

RF35 — Verificação de respostas (TIR com SymPy)

Descrição: Validar cálculos numéricos e simbólicos com ferramenta externa.

Módulos: M05, M02

Critérios de aceitação: - [ ] Ferramenta SymPy integrada ao agente (RF09) - [ ] Respostas com resultado numérico passam por verificação antes de envio - [ ] Divergência LLM vs SymPy: priorizar SymPy e sinalizar correção ao usuário - [ ] Log de verificações no LangSmith

---

RF36 — Metadados por documento

Descrição: Cada documento indexado deve ter metadados estruturados.

Módulos: M06, M08

Critérios de aceitação: - [ ] Campos obrigatórios: `titulo`, `fonte`, `tipo` (apostila, exercício, BNCC) - [ ] Campos opcionais: `serie` (1/2/3 EM), `tema`, `habilidade_bncc`, `autor`, `ano_letivo` - [ ] Metadados consultáveis como filtro no retriever (ex.: `serie=2`)

RF37 — Política de abstinência

Descrição: Não responder quando confiança ou recuperação forem insuficientes.

Módulos: M02, M04

Critérios de aceitação: - [ ] Se max score de retrieval < limiar configurável: resposta padrão “Não encontrei material suficiente…” - [ ] Sem citação de fonte → não afirmar fatos do corpus - [ ] Mensagem sugere reformular pergunta ou consultar professor - [ ] Taxa de abstinência monitorada no dashboard (RNF12)

RF38 — Avaliação contínua da qualidade RAG

Descrição: Conjunto de testes de regressão para qualidade de recuperação e geração.

Módulos: M09, M10

Critérios de aceitação: - [ ] Dataset de ≥ 50 perguntas com resposta esperada e fonte esperada - [ ] Métricas: precision@5, faithfulness, citation_accuracy - [ ] Script `scripts/eval_rag.py` executável em CI - [ ] Regressão > 5% em qualquer métrica bloqueia deploy (RNF15)

RF39 — Reindexação incremental e versionamento

Descrição: Atualizar índice sem reprocessar corpus inteiro; versionar coleções.

Módulos: M06, M07

Critérios de aceitação: - [ ] Adicionar/remover documento sem reindexação completa - [ ] Nova versão de coleção (ex.: `v2`) criável em paralelo; switch por configuração - [ ] Rollback para versão anterior em < 5 minutos

---

RF40 — Integração WhatsApp Cloud API

Descrição: Comunicação com clientes via WhatsApp Business Cloud API (Meta).

Módulos: M01

Critérios de aceitação: - [ ] Webhook HTTPS público com verificação `hub.challenge` - [ ] Validação de assinatura `X-Hub-Signature-256` - [ ] Resposta HTTP 200 em < 1s; processamento assíncrono via fila (Redis/RQ, Celery ou equivalente) - [ ] Envio de resposta via Graph API com `phone_number_id` e token de sistema - [ ] Suporte a janela de 24h e templates para mensagens fora da janela - [ ] Documentação de setup em `docs/WHATSAPP.md`

RF41 — Idempotência de mensagens WhatsApp

Descrição: Evitar processamento duplicado de webhooks.

Módulos: M01

Critérios de aceitação: - [ ] `message_id` persistido com TTL ≥ 48h - [ ] Segundo webhook com mesmo `message_id` retorna 200 sem reprocessar - [ ] Teste automatizado simula retry da Meta

---

RF42 — Consentimento e opt-out

Descrição: Fluxo de consentimento LGPD/ECA Digital e cancelamento.

Módulos: M01, M09

Critérios de aceitação: - [ ] Primeira interação: mensagem de termos + opção de aceitar/recusar - [ ] Comando `SAIR` ou equivalente: interrompe processamento e marca opt-out - [ ] Registro de consentimento: `timestamp`, `phone_hash`, `version_termos` - [ ] Sem consentimento: apenas mensagem informativa, sem RAG

RF43 — Modos pedagógicos (tutor vs avaliação)

Descrição: Diferenciar explicação passo a passo de entrega direta de gabarito.

Módulos: M02, M06

Critérios de aceitação: - [ ] Modo tutor (padrão): scaffolding, pistas, não entrega resposta final de prova - [ ] Modo avaliação: ativado por flag admin; apenas referência a material, sem resolver lista - [ ] Detecção heurística de “me dá a resposta da prova” → recusa educada

---

RF44 — Dashboard web de controle

Descrição: Painel para gestão do sistema RAG sem sobrecarregar o servidor.

Módulos: M10

Critérios de aceitação: - [ ] Telas: status dos serviços, métricas (latência, abstinência, mensagens/dia) - [ ] Gestão de corpus: upload, listagem, reindexação - [ ] Visualização de chunks e metadados BNCC - [ ] Acesso a traces LangSmith (link externo ou embed) - [ ] RBAC: admin, operador, somente leitura (RNF14)

RF45 — Tratamento de tabelas e imagens em PDFs

Descrição: Preservar estrutura de tabelas e descrição de figuras para RAG.

Módulos: M06

Critérios de aceitação: - [ ] Tabelas extraídas como Markdown ou CSV embutido no chunk - [ ] Imagens/figuras: descrição textual ou alt-text quando OCR/disponível - [ ] Teste com ≥ 3 PDFs contendo tabelas de exercícios

---

RF46 — Orçamento de tokens para Qwen2.5-Math (4K)

Descrição: Toda montagem de prompt, memória e retrieval deve respeitar a janela de **4.096 tokens** do `Qwen2.5-Math-1.5B-Instruct`.

Módulos: M02, M03, M04, M05

Critérios de aceitação: - [ ] Documento `docs/TOKEN_BUDGET.md` implementado no código - [ ] Contagem com tokenizer Qwen (`AutoTokenizer` do modelo) - [ ] Orçamento padrão: sistema 400 + RAG 1.200 + histórico 800 + usuário 400 + geração 1.024 - [ ] Truncagem em ordem de prioridade (RAG → histórico → usuário) conforme TOKEN_BUDGET - [ ] LangSmith registra `input_tokens`, `rag_tokens`, `history_tokens`, `output_tokens` - [ ] Teste TB-01 a TB-05 de `docs/TOKEN_BUDGET.md` passando em CI - [ ] Não usar `VLLM_ALLOW_LONG_MAX_MODEL_LEN` em produção

---

RF47 — Sistema integralmente auditável (ECA Digital + LGPD)

Descrição: Todo o projeto deve ser auditável de ponta a ponta: canais, pipeline RAG, administração, consentimento e incidentes. A auditoria é obrigatória por força do ECA Digital (Lei 15.211/2025) e da LGPD, não opcional.

Módulos: M01–M10, M09 (camada transversal)

Critérios de aceitação: - [ ] Arquitetura documentada em `docs/AUDITORIA_ECA.md` - [ ] Tabela `audit_log` append-only com schema definido (event_id, correlation_id, actor, action, outcome, metadata) - [ ] Tabela `consent_log` imutável para aceite/recusa de termos - [ ] **Fail-closed:** se gravação de log falhar, não processar mensagem de menor - [ ] LangSmith (RF31) como camada técnica complementar — **não substitui** log local - [ ] Todos os eventos obrigatórios da seção 5 de AUDITORIA_ECA implementados - [ ] Script `scripts/export_audit.py` para relatórios da escola/DPO - [ ] Testes AU-01 a AU-07 passando - [ ] Retenção: audit_log 12 meses; consent_log 5 anos - [ ] Dashboard: tela de consulta de logs (papel admin/DPO, RBAC R13)

---

4. Requisitos não funcionais

RNF01 — Stack LangChain, LangGraph e LangSmith

Critérios de aceitação: - [ ] LangGraph para orquestração de agentes - [ ] LangSmith para tracing em todos os ambientes não locais - [ ] Versões fixadas e testadas em conjunto

---

RNF02 — Bancos vetoriais por ambiente

Ambiente	Banco
Desenvolvimento / testes	Chroma
Produção	Qdrant (padrão) ou pgvector (se ADR aprovar)

Critérios de aceitação: - [ ] Variável `VECTOR_STORE_PROVIDER` seleciona implementação - [ ] Testes de integração rodam contra Chroma em CI

RNF03 — Sistema operacional

Critérios de aceitação: - [ ] Ubuntu Server 22.04 LTS ou 24.04 LTS - [ ] Documentação de instalação testada em Ubuntu limpo

---

RNF04 — API WhatsApp

Critérios de aceitação: - [ ] WhatsApp Business Cloud API (Meta) como canal oficial - [ ] Twilio ou BSP alternativo permitido se compatível com Cloud API - [ ] Domínio com TLS válido para webhook

---

RNF05 — Engenharia de prompt

Critérios de aceitação: - [ ] Prompts versionados em arquivos, não hardcoded - [ ] Revisão de prompt exige PR e teste de regressão (RF38)

RNF06 — Interface web leve

Critérios de aceitação: - [ ] Frontend estático ou SSR leve (FastAPI + Jinja, ou SPA mínima) - [ ] Não exige GPU no cliente - [ ] Tempo de carregamento inicial < 3s em rede local

---

RNF07 — Containerização Docker modular

Critérios de aceitação: - [ ] `docker-compose.yml` com serviços: `api`, `worker`, `qdrant`, `redis`, `dashboard` (opcional) - [ ] Cada serviço com Dockerfile próprio - [ ] Volumes para dados persistentes (índice, uploads, memória) - [ ] Healthcheck em cada container

---

RNF08 — Arquitetura reutilizável (base para outros RAGs)

Critérios de aceitação: - [ ] Troca de domínio (ex.: Física) alterando: corpus, prompts, metadados — sem reescrever core - [ ] Interfaces `Protocol` ou ABC documentadas em `app/core/interfaces/`

RNF09 — Modelo LLM

Critérios de aceitação: - [ ] `Qwen2.5-Math-1.5B-Instruct` como padrão - [ ] Contexto máximo: **4.096 tokens** (série Math; não confundir com Qwen2.5 genérico 128K) - [ ] Requisito mínimo de hardware documentado: 8 GB RAM (CPU) ou 6 GB VRAM (GPU) - [ ] Variável `LLM_MODEL` para override em testes - [ ] Variáveis de orçamento em `.env.example`: `RAG_CONTEXT_MAX_TOKENS`, `HISTORY_MAX_TOKENS`, `LLM_MAX_NEW_TOKENS`

RNF10 — Idioma

Critérios de aceitação: - [ ] Português brasileiro como idioma principal de interface e respostas - [ ] Embeddings multilíngues compatíveis com PT

RNF11 — Desempenho

Critérios de aceitação: - [ ] p95 latência end-to-end WhatsApp (mensagem recebida → resposta enviada) < 30s em hardware de referência - [ ] p95 retrieval < 2s - [ ] p95 geração LLM < 20s (1.5B, CPU aceitável com aviso)

RNF12 — Observabilidade

Critérios de aceitação: - [ ] Logs estruturados (JSON) com `correlation_id` - [ ] Métricas Prometheus ou equivalente: `rag_latency`, `retrieval_score`, `abstention_rate` - [ ] Alertas configuráveis para erro > 5% em 5 minutos

---

RNF13 — Segurança

Critérios de aceitação: - [ ] Segredos em variáveis de ambiente ou vault, nunca em código - [ ] `ADMIN_API_KEY` ou OAuth para endpoints administrativos - [ ] Rate limit por IP e por número WhatsApp - [ ] HTTPS obrigatório em produção

---

RNF14 — Controle de acesso (RBAC)

Critérios de aceitação: - [ ] Papéis: `admin`, `operator`, `viewer` - [ ] Matriz de permissões documentada em `docs/RBAC.md`

RNF15 — CI/CD e qualidade

Critérios de aceitação: - [ ] Pipeline CI: lint, testes unitários, `eval_rag.py` em dataset reduzido - [ ] Regressão de métricas RAG bloqueia merge na branch principal - [ ] Build de imagens Docker em cada release tag

---

RNF16 — Backup e recuperação

Critérios de aceitação: - [ ] Backup diário: banco vetorial, metadados, corpus em `data/materials` - [ ] Procedimento de restore documentado e testado trimestralmente - [ ] RPO ≤ 24h; RTO ≤ 4h

---

RNF17 — Escalabilidade horizontal (fase F3)

Critérios de aceitação: - [ ] Workers de fila escaláveis (`docker compose up --scale worker=3`) - [ ] API stateless; estado em banco/fila

---

---

5. Matriz de rastreabilidade

5.1 RF → Módulo → Fase → Teste

RF	Módulo(s)	Fase	ID Teste
RF01	M02, M05, M01	F1	T-01
RF02	M02, M04, M05, M06	F1	T-02
RF03	M03, M02	F1	T-03
RF04	M02	F1	T-04
RF05	M01, M10	F1	T-05
RF06	M02, M05	F1	T-06
RF07	M02, M03	F1	T-07
RF08	M03	F1	T-08
RF09	M02, M05	F1	T-09
RF10	M02, M05	F1	T-10
RF11	M03, M02	F1	T-11
RF12	M02–M07	F1	T-12
RF13	M04	F1	T-13
RF14	M05	F1	T-14
RF15	M06, M07, M08	F1	T-15
RF16	M06	F1	T-16
RF17	M06	F1	T-17
RF18	M06	F1	T-18
RF19	M06	F3	T-19
RF20	M06	F1	T-20
RF21	M04, M06	F1	T-21
RF22	M06, M07	F1	T-22
RF23	M06	F1	T-23
RF24	M07	F1/F3	T-24
RF25	M04, M07	F1	T-25
RF26	M04	F2	T-26
RF27	M06, M09	F2	T-27
RF28	M02, M05	F3	T-28
RF29	M02, M01, M10	F1	T-29
RF30	M09	F2	T-30
RF31	M09, M02	F1	T-31
RF32	M09, M01	F3	T-32

RF	Módulo(s)	Fase	ID Teste
RF33	M08, M02, M05	F3	T-33
RF34	M05, M01, M10	F1	T-34
RF35	M05, M02	F1	T-35
RF36	M06, M08	F1	T-36
RF37	M02, M04	F1	T-37
RF38	M09, M10	F2	T-38
RF39	M06, M07	F2	T-39
RF40	M01	F2	T-40
RF41	M01	F2	T-41
RF42	M01, M09	F2	T-42
RF43	M02, M06	F2	T-43
RF44	M10	F2/F3	T-44
RF45	M06	F2	T-45
RF46	M02, M03, M04, M05	F1	T-46
RF47	M01–M10, M09	F2/F3	T-47

5.2 RNF → Módulo → Verificação

RNF	Módulo(s)	Verificação
RNF01	M02, M09	Inspeção de dependências + trace LangSmith
RNF02	M07	Teste integração Chroma (CI) + Qdrant (staging)
RNF03	Infra	Instalação Ubuntu limpa
RNF04	M01	Webhook Meta verificado
RNF05	M02, M05	PR review + eval
RNF06	M10	Lighthouse / tempo de carga
RNF07	Infra	`docker compose up` completo
RNF08	Core	Troca de domínio em spike
RNF09	M05	Benchmark latência
RNF10	Todos	Revisão de conteúdo PT
RNF11	Todos	Teste de carga k6 ou locust
RNF12	M09, M10	Dashboard Grafana/Prometheus
RNF13	M01, M10	Pentest básico / OWASP ZAP
RNF14	M10	Matriz RBAC
RNF15	CI	Pipeline verde
RNF16	Infra	Drill de restore
RNF17	Infra	Scale workers

5.3 Mapeamento requisitos originais → novos

Original	Novo	Observação
RF1	RF01	Tom pedagógico EM
RF2	RF02	Mantido
RF3	RF03	Mantido
RF4	RF04	LangGraph substitui ConversationChain
RF5	RF05	Mantido
RF6	RF06	Escopo matemática EM
RF7	RF07	Mantido
RF8	RF08	Mantido
RF9	RF09	Mantido
RF10	RF10	Mantido
RF11	RF11	Mantido
RF13	RF12	Renumeração
RF14	RF13	Híbrido unificado
RF15	RF14	Modelo de domínio, não fine-tune obrigatório
RF16	RF15	Mantido
RF17	RF12	Integrado ao orquestrador
RF19	RF16	Mantido
RF20	RF17	Mantido
RF21 (duplicado)	RF18, RF19	Separado multi-formato vs web
RF21 chunking	RF20	Preservação LaTeX
RF22	RF21	Parent-document
RF23	RF22	Mantido
RF24	RF23	Mantido
RF25	RF24	Chroma + Qdrant definido
RF26	RF25	Mantido
RF27	RF13	Unificado
RF28	RF27	Mantido
RF29	RF28	Mantido
RF30	RF29	Mantido
RF31	RF30	LGPD operacional
RF32	RF31	Mantido
RF33	RF32	ECA Digital como checklist

Original	Novo	Observação
RF34	RF33	BNCC operacional
RNF1–RNF10	RNF01–RNF17	Expandido e detalhado
—	RF34–RF45	Novos (matemática, WhatsApp, avaliação)
—	RNF11–RNF17	Novos (perf, segurança, backup)

---

6. Plano de testes de aceitação (resumo)

ID	Descrição	RF/RNF	Tipo
T-01	20 perguntas piloto — avaliação de tom	RF01	Manual
T-04	Grafo LangGraph executa sem ConversationChain	RF04	Automatizado
T-13	Benchmark híbrido vs denso (30 perguntas)	RF13	Automatizado
T-14	Qwen2.5-Math-1.5B-Instruct responde equação	RF14	Automatizado
T-29	Resposta inclui citação com página	RF29	Automatizado
T-35	SymPy corrige divergência de cálculo	RF35	Automatizado
T-37	Score baixo → mensagem de abstinência	RF37	Automatizado
T-38	`eval_rag.py` — precision@5 ≥ 0.7	RF38	CI
T-40	Webhook Meta end-to-end em staging	RF40	Integração
T-41	Retry duplicado não gera segunda resposta	RF41	Automatizado
T-42	Sem consentimento → sem RAG	RF42	Integração
T-32	Checklist ECA Digital 100% itens obrigatórios	RF32	Manual
T-33	Resposta cita EM13MAT quando aplicável	RF33	Manual
T-46	Entrada do prompt ≤ 2.900 tokens; geração ≤ 1.024	RF46	Automatizado
T-47	Mensagem menor gera audit_log + LangSmith; fail-closed se log falhar	RF47	Integração
AU-01 a AU-07	Bateria de auditoria ECA	RF47	Ver `AUDITORIA_ECA.md`

7. Glossário de habilidades BNCC (referência)

O sistema deve suportar as **5 competências específicas** de Matemática no EM:

1. Utilizar estratégias e conceitos para interpretar e resolver problemas
2. Analisar relações entre grandezas para modelagem matemática
3. Investigar e produzir conjecturas com linguagem matemática
4. Compreender e utilizar diferentes registros de representação
5. Investigar e estabelecer conjecturas com abordagem formal

Códigos de habilidade seguem o padrão `EM13MATnnn` (ex.: EM13MAT101). O catálogo completo deve ser importado do documento oficial MEC para M08.

---

8. Aprovações

Papel	Nome	Data	Assinatura
Product Owner			
Tech Lead			
Responsável pedagógico			
DPO / Privacidade			

---

9. Histórico de revisões

Versão	Data	Autor	Alteração
1.0	29/06/2026	deepEdu	Versão inicial revisada a partir da análise de requisitos
1.1	29/06/2026	deepEdu	Orçamento de tokens Qwen2.5-Math 4K (RF46, TOKEN_BUDGET, prompts)
1.2	29/06/2026	deepEdu	RF47 auditoria integral ECA; docs/AUDITORIA_ECA.md

Parte II — Orçamento de Tokens (Qwen2.5-Math 4K)

Campo	Valor
Modelo	`Qwen2.5-Math-1.5B-Instruct`
Janela de contexto	**4.096 tokens** (`max_position_embeddings`)
Tokenizer	`Qwen/Qwen2.5-Math-1.5B-Instruct` (via `transformers` ou `tiktoken` compatível)
Versão	1.0
Data	29/06/2026

> **Importante:** A série **Qwen2.5-Math** usa janela de **4K**, não os 128K do Qwen2.5 genérico. Forçar contexto maior (`VLLM_ALLOW_LONG_MAX_MODEL_LEN`) **não é recomendado** — causa saídas incorretas ou erros CUDA.

---

1. Distribuição do orçamento (padrão produção)

Componente	Máximo (tokens)	Variável de config	Observação
Prompt de sistema	400	`PROMPT_MAX_TOKENS`	Ver `prompts/v1_tutor_em.md` (~250–350 na prática)
Contexto RAG (total)	1.200	`RAG_CONTEXT_MAX_TOKENS`	Soma de todos os chunks injetados
Histórico de chat	800	`HISTORY_MAX_TOKENS`	Buffer + resumo (RF08)
Mensagem do usuário	400	`USER_MESSAGE_MAX_TOKENS`	Truncar se exceder; pedir reformulação
Overhead (tags, formatação)	100	—	Marcadores `<context>`, etc.
Subtotal de entrada	**~2.900**		
Geração (`max_new_tokens`)	**1.024**	`LLM_MAX_NEW_TOKENS`	Resposta do tutor
Total estimado	**~3.924**		Margem de segurança: ~172 tokens

---

2. Regras de truncagem (ordem de prioridade)

Quando a entrada exceder o limite, aplicar **nesta ordem**:

1. **Truncar chunks RAG** — reduzir de `top_k=3` para `top_k=2`, depois `top_k=1`
2. **Resumir histórico** — acionar resumo automático (RF08) mantendo tema e dados do problema
3. **Truncar chunks individualmente** — cada chunk a no máximo 400 tokens (corte por fim de parágrafo)
4. **Truncar mensagem do usuário** — apenas se > 400 tokens; avisar o usuário
5. **Nunca truncar** o prompt de sistema abaixo de 200 tokens (persona + regras críticas)

Se ainda exceder após truncagem: **abstinência** (RF37) com mensagem pedindo pergunta mais curta.

---

3. Parâmetros RAG alinhados ao orçamento

Parâmetro	Valor padrão	Justificativa
`RETRIEVAL_TOP_K`	3	3 × 400 tokens = 1.200 tokens de contexto
`CHUNK_CHILD_TOKENS`	300–400	Busca granular sem estourar janela
`CHUNK_PARENT_MAX_TOKENS`	400	**Corrigido** — não 1.500 (incompatível com 4K)
`LLM_MAX_NEW_TOKENS`	1.024	Respostas pedagógicas com passos
`LLM_TEMPERATURE`	0.3	Menor variância em matemática
`HISTORY_BUFFER_MESSAGES`	4	Últimas 4 trocas antes de resumir
`HISTORY_SUMMARY_TRIGGER`	600 tokens	Dispara resumo do histórico

---

4. Contagem de tokens

Obrigatório: usar o tokenizer do próprio modelo Qwen para contagem — **não** estimar por caracteres.

```
from transformers import AutoTokenizer

tokenizer = AutoTokenizer.from_pretrained("Qwen/Qwen2.5-Math-1.5B-Instruct")

def count_tokens(text: str) -> int:
    return len(tokenizer.encode(text, add_special_tokens=False))
```

Registrar no LangSmith (RF31): `input_tokens`, `rag_tokens`, `history_tokens`, `output_tokens`.

---

5. Limites por canal

WhatsApp

- Mensagem típica do aluno: 50–150 tokens
- Resposta alvo: 200–600 tokens (evitar textos longos; usar passos numerados curtos)
- Se resposta > 800 tokens: dividir em 2 mensagens sequenciais

Dashboard web

- Mesmos limites de entrada

- Pode exibir resposta completa até `max_new_tokens`

---

6. Template de montagem do prompt

```
[System — máx. 400 tokens]
{prompts/v1_tutor_em.md}

[Contexto RAG — máx. 1.200 tokens]
<context>
{chunk_1}
---
{chunk_2}
---
{chunk_3}
</context>

[Histórico — máx. 800 tokens]
{history_summary_or_buffer}

[Usuário — máx. 400 tokens]
{user_message}
```

---

7. Testes de aceitação

ID	Teste	Critério
TB-01	Prompt sistema	≤ 400 tokens
TB-02	3 chunks + histórico médio + pergunta	Entrada ≤ 2.900 tokens
TB-03	Pergunta com 10 turnos de conversa	Resumo ativado; sem erro de contexto
TB-04	Pergunta de 2.000 caracteres	Truncada ou recusa educada
TB-05	LangSmith trace	Campos de token preenchidos

---

8. Referência técnica

- `config.json` do modelo: `max_position_embeddings: 4096`
- Qwen2.5-Math Technical Report — treino com context length 4K
- Hugging Face — Qwen2.5-Math-1.5B-Instruct

Parte III — Auditoria Integral (ECA Digital)

Campo	Valor
Sistema	deepEdu — Tutor RAG de Matemática (Ensino Médio)
Base legal	Lei 15.211/2025 (ECA Digital) + Lei 13.709/2018 (LGPD)
Versão	1.0
Data	29/06/2026

---

1. Princípio fundamental

> **Todo o projeto é auditável.** Nenhum módulo, canal ou operação que envolva dados de menores pode operar sem rastreio. A escola, o DPO e a ANPD devem poder reconstruir *quem fez o quê, quando, com qual base legal e qual resultado*.

A auditoria não se limita ao LangSmith: é uma **camada transversal** (M09) que cobre fluxo técnico, pedagógico, administrativo e legal.

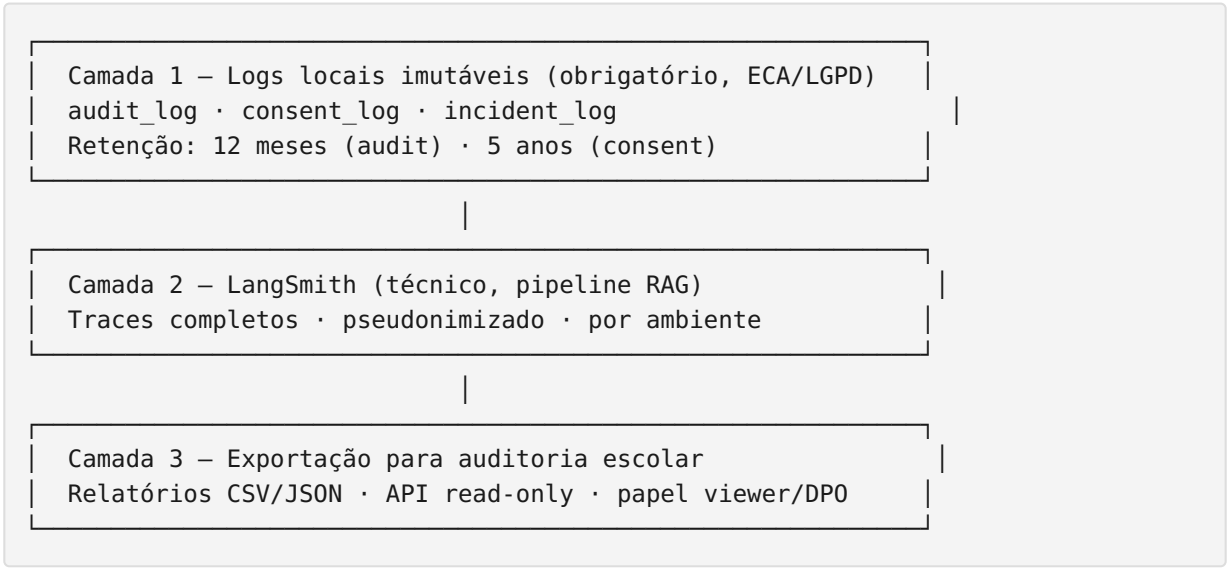
---

2. Escopo da auditabilidade

Área	O que deve ser auditado	Onde persiste
WhatsApp (entrada/ saída)	`message_id`, direção, timestamp, `phone_hash`, consentimento ativo	`audit_log` + LangSmith
Consentimento ECA	aceite/recusa, versão dos termos, IP/hash	`consent_log` (imutável)
Pipeline RAG	query, chunks, scores, prompt montado, tokens, resposta	LangSmith + `audit_log` resumo
LLM / SymPy	modelo, parâmetros, verificação numérica	LangSmith trace
Memória de sessão	criação, resumo, exclusão (LGPD)	`audit_log`
Corpus (admin)	upload, delete, reindex, versão do índice	`audit_log`
Dashboard (admin)	login, ações RBAC (R04–R16)	`audit_log`
Incidentes	vazamento, acesso indevido, falha de segurança	`incident_log`
Fornecedores	exportações para Meta, LangSmith	ROPA + logs de integração

---

3. Três camadas de auditoria



---

4. Schema do log de auditoria (`audit_log`)

Cada evento **obrigatório** contém:

Campo	Tipo	Descrição
`event_id`	UUID	Identificador único
`timestamp`	ISO 8601 UTC	Momento do evento
`correlation_id`	UUID	Liga eventos da mesma requisição
`actor_type`	enum	`student`, `admin`, `system`, `webhook`
`actor_id`	string	`phone_hash`, `user_id` ou `system`
`session_id`	string	Pseudonimizado
`action`	string	Ex.: `message.received`, `rag.generate`, `corpus.upload`
`resource`	string	Ex.: `chunk:abc123`, `document:apostila.pdf`
`outcome`	enum	`success`, `failure`, `abstained`, `denied`
`metadata`	JSON	Scores, token counts, `bncc_skill` — **sem PII em claro**
`langsmith_run_id`	string	Link para trace (quando aplicável)

Regras: - Logs **append-only** (sem UPDATE/DELETE) - PII nunca em claro: usar `phone_hash`, `session_id` pseudonimizado - Falha ao gravar log → **não processar** a mensagem do menor (fail-closed)

---

5. Eventos obrigatórios por módulo

M01 — WhatsApp

- `webhook.received`, `webhook.signature_invalid`, `message.received`, `message.sent`, `message.duplicate_skipped`

M02 — Orquestrador

- `rag.started`, `rag.completed`, `rag.abstained`, `rag.failed`, `tokens.budget_exceeded`

M03 — Memória

- `session.created`, `history.summarized`, `session.deleted` (solicitação LGPD)

M04 — Retriever

- `retrieval.executed` (top_k, scores, chunk_ids)

M05 — Gerador

- `llm.invoked`, `sympy.verified`, `sympy.divergence`

M06/M07 — Ingestão / Índice

- `corpus.document_added`, `corpus.document_removed`, `index.rebuilt`, `index.version_switched`

M09 — Governança

- `consent.granted`, `consent.revoked`, `optout.requested`
- `admin.login`, `admin.action_denied` (RBAC)
- `incident.reported`

---

6. LangSmith (RF31) — complemento, não substituto

Aspecto	LangSmith	Log local
Finalidade	Debug técnico, qualidade RAG	Conformidade legal ECA/LGPD
PII	Proibido nos traces	Apenas hashes
Retenção	Política LangChain	12 meses mínimo
Acesso escola	Via export/API	Dashboard + export direto
Obrigatório em prod	Sim	**Sim — independente**

Variáveis obrigatórias:

```
LANGCHAIN_TRACING_V2=true
LANGCHAIN_PROJECT=deepedu-prod
LANGSMITH_API_KEY=...
```

Tags em cada trace: `session_id`, `phone_hash`, `channel`, `consent_version`, `bncc_skill`.

---

7. Transparência para o usuário (ECA Art. 8º e boas práticas)

Na **primeira interação** (RF42), mensagem obrigatória:

> “Olá! Sou o tutor de Matemática da [escola]. Para te ajudar, registro nossas conversas de forma segura, conforme a política de privacidade da escola e a lei de proteção de menores no ambiente digital. Seus pais/responsáveis autorizaram este uso. Para parar, envie SAIR.”

O prompt do sistema **não deve** afirmar que conversas são anônimas ou não registradas.

---

8. Exportação para auditoria escolar

Endpoint ou script (papel `admin` / DPO):

```
python scripts/export_audit.py \
  --from 2026-01-01 --to 2026-06-30 \
  --format csv \
  --output relatorio_auditoria_escola.csv
```

Conteúdo exportável: - Resumo de consentimentos - Volume de mensagens por período (sem conteúdo, se política restritiva) - Ações administrativas - Incidentes - Metadados RAG (abstinência, fontes citadas)

Conteúdo de mensagens: apenas com base legal e autorização expressa do DPO.

---

9. Direito de auditoria da escola (ECA Digital)

Contrato com a instituição deve garantir: - Acesso a logs e relatórios mediante solicitação - Notificação de incidentes em **24 horas** - Suporte a fiscalização da ANPD - Exclusão de dados ao término do contrato com comprovante

Ver checklist: `docs/ECA_DIGITAL_CHECKLIST.md` itens 4.3, 4.4, 6.3.

---

10. Testes de aceitação (auditoria)

ID	Teste	Critério
AU-01	Mensagem WhatsApp processada	≥ 1 evento em `audit_log` + trace LangSmith
AU-02	Consentimento negado	Nenhum evento `rag.*`; apenas `consent.revoked`
AU-03	Upload de corpus	`corpus.document_added` com `user_id`
AU-04	Falha de gravação de log	Mensagem **não** processada (fail-closed)
AU-05	Exportação 30 dias	CSV gerado sem PII em claro
AU-06	Exclusão LGPD (SAIR)	`session.deleted` + dados removidos
AU-07	Ação RBAC negada	`admin.action_denied` registrado

---

11. Responsabilidades

Papel	Responsabilidade
Desenvolvimento	Implementar `audit_log` em todos os módulos
DPO	Validar ROPA, DPIA, exportações
Escola	Auditoria periódica, contratos com fornecedores
Operação	Monitorar incidentes, backups de logs

---

12. Referências cruzadas

- RF30 — Privacidade LGPD
- RF31 — LangSmith
- RF32 — ECA Digital
- RF42 — Consentimento
- RF46 — Orçamento de tokens (registrar tokens no audit)
- `docs/ROPA.md`
- `docs/ECA_DIGITAL_CHECKLIST.md`
- `docs/RBAC.md` — R13 `audit.logs`

Parte IV — Revisão v3.0 (implementação completa)

Campo	Valor
Versão	3.0
Data	29/06/2026
Status	**Sem pendências de implementação**

1. Correções aplicadas (F01–F22)

ID	Falha original	Correção
F01	LangSmith ausente	`configure_langsmith()` + `collect_runs()`
F02	Telefone em claro no chat	`pseudonymize_session_id(phone)`
F03	Telefone em claro no billing	`phone_vault` + `phone_hash`
F04	Verificação de idade ausente	`student_enrollment` + `VINCULAR`
F05	Consentimento simplificado	`parental_consent_ref` no enroll
F06	DeepSeek no RAG	`llm_factory.py` → Qwen2.5-Math
F07	Indexação sem audit	`corpus.document_added`, `index.rebuilt`
F08	Retrieval/LLM sem log	`AuditedRetriever`, `rag.*`, `llm.invoked`
F09	incident_log ausente	`POST /admin/incidents`
F10	Dashboard logs ausente	`GET /admin/audit/logs` + CSV
F11	Testes ausentes	`tests/test_audit_core.py`, `tests/test_extras.py`
F12	dedup sem TTL	`cleanup_message_dedup()` no startup
F13	Admin sem audit	`@audited_admin_action`
F14	Token budget ausente	`token_budget.py`
F15	Prompts não usados	`prompt_loader.py`
F16	SymPy ausente	`sympy_tool.py`
F17	Abstinência RAG ausente	`abstinence.py` + `RETRIEVAL_MIN_SCORE`
F18	langsmith_run_id vazio	`collect_runs()`
F19	Migração billing legado	`_migrate_legacy_plain_phones()`
F20	Só Twilio	`meta_webhook.py`
F21	Dashboard sem auditoria	Streamlit aba ECA
F22	Admin parcial sem audit	Decorators em todas rotas sensíveis

2. Itens adicionais v3.0 (ex-pendências)

Item	Implementação
RF08 resumo de memória	`app/memory/summarizer.py`
RF26 re-ranking	`app/rag/reranker.py` (cross-encoder)
RF38 avaliação RAG	`scripts/eval_rag.py` + dataset 50 perguntas
RNF15 CI	`.github/workflows/ci.yml`
RNF16 backup	`scripts/backup_data.sh`
P01 Ollama	`scripts/install_ollama_model.sh`
P02 segredos produção	`app/core/startup_checks.py`
P03 DPIA	`docs/DPIA.md`
P04 criptografia repouso	`docs/SEGURANCA_DADOS.md` + LUKS/perm
P09 dataset 50	`docs/eval/dataset_rag_matematica_em.csv` (50 ativas)
Casos de uso	`docs/CASOS_DE_USO.md` (64 UC = RF+RNF)

---

3. Matriz AU — status

Teste	Status
AU-01 audit + pipeline	**OK**
AU-02 sem consentimento sem RAG	**OK**
AU-03 upload corpus	**OK**
AU-04 fail-closed	**OK**
AU-05 export sem PII clara	**OK**
AU-06 SAIR exclui sessão	**OK**
AU-07 RBAC negado	**OK**

---

4. Pendências

Nenhuma pendência de implementação no repositório.

Ações operacionais na escola (fora do código): assinar DPIA/ROPA, configurar `.env` de produção, executar `install_ollama_model.sh`, revisão jurídica do texto de consentimento.

---

5. Comandos de verificação

```
python -m unittest discover -s tests -p "test_*.py" -v
python scripts/eval_rag.py --output reports/eval_latest.json
python scripts/export_audit.py --output reports/audit.csv
bash scripts/backup_data.sh
python scripts/build_documento_pdf.py
```

---

6. Histórico

Versão	Data	Alteração
1.0	29/06/2026	Identificação F01–F24
2.0	29/06/2026	Correções críticas ECA
3.0	29/06/2026	Zero pendências; UC; dataset 50; RF26/RF08

Parte V — Casos de Uso (RF e RNF)

Campo	Valor
Versão	1.0
Projeto	deepEdu — Tutor RAG Matemática EM
Base	`docs/REQUISITOS.md` v1.2
Formato	Um caso de uso por RF/RNF

---

1. Visão geral

Cada caso de uso (UC) rastreia diretamente um requisito funcional (RF) ou não funcional (RNF). Atores principais: **Estudante EM**, **Administrador/DPO**, **Operador**, **Sistema deepEdu**.

Diagrama de contexto

```
Estudante ──WhatsApp──► deepEdu API ──► RAG (retrieval + Qwen + SymPy)
                                │
Administrador ──painel/API──►├──► audit_log / LangSmith
DPO ──export─────────────────┘
```

---

2. Casos de uso funcionais (RF)

UC-RF01 — Chatbot pedagógico coloquial

Campo	Valor
Requisito	RF01
Módulos	M02, M05, M01
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** O sistema deve responder consultas em linguagem coloquial e acessível a adolescentes (15–17 anos), mantendo rigor matemático.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Chatbot pedagógico coloquial».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF01.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF02 — Configuração do ecossistema LangChain

Campo	Valor
Requisito	RF02
Módulos	M02, M04, M05, M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Utilizar LangChain como base de composição de componentes (loaders, retrievers, chains/runnables).

Fluxo principal:

1. Estudante EM envia ação relacionada a «Configuração do ecossistema LangChain».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).

3. Sistema executa pipeline necessário para RF02.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF03 — Memória de conversa multi-turno

Campo	Valor
Requisito	RF03
Módulos	M03, M02
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Manter contexto entre mensagens da mesma sessão para conversas com múltiplas trocas.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Memória de conversa multi-turno».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF03.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF04 — Orquestração com LangGraph

Campo	Valor
Requisito	RF04
Módulos	M02
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Orquestrar o fluxo conversacional com LangGraph e checkpointer (substitui `ConversationChain`, depreciado).

Fluxo principal:

1. Estudante EM envia ação relacionada a «Orquestração com LangGraph».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF04.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF05 — Interface web de chat (teste e admin)

Campo	Valor
Requisito	RF05
Módulos	M01, M10
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Interface web simples para interação com o chatbot e testes internos.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Interface web de chat (teste e admin)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF05.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF06 — Prompts personalizados para Matemática EM

Campo	Valor
Requisito	RF06
Módulos	M02, M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Prompts de sistema versionados para tutoria em Matemática do Ensino Médio.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Prompts personalizados para Matemática EM».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF06.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF07 — Consciência de contexto em conversas

Campo	Valor
Requisito	RF07
Módulos	M02, M03
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Utilizar histórico, intenção e entidades para respostas contextualizadas.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Consciência de contexto em conversas».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).

3. Sistema executa pipeline necessário para RF07.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF08 — Gestão otimizada de memória

Campo	Valor
Requisito	RF08
Módulos	M03
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Combinar memória de buffer e resumo; limitar detalhes desnecessários.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Gestão otimizada de memória».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF08.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF09 — Decomposição de consultas e ferramentas externas

Campo	Valor
Requisito	RF09
Módulos	M02, M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Decompor consultas complexas em subtarefas; usar ferramentas (APIs, calculadora, SymPy).

Fluxo principal:

1. Estudante EM envia ação relacionada a «Decomposição de consultas e ferramentas externas».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF09.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF10 — Síntese coerente de respostas

Campo	Valor
Requisito	RF10
Módulos	M02, M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Integrar resultados de retrieval e ferramentas numa resposta única e coerente.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Síntese coerente de respostas».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF10.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF11 — Armazenamento e atualização dinâmica de contexto

Campo	Valor
Requisito	RF11
Módulos	M03, M02
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Armazenar entradas, intenções e entidades; atualizar com novas mensagens.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Armazenamento e atualização dinâmica de contexto».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF11.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF12 — Arquitetura RAG (componentes obrigatórios)

Campo	Valor
Requisito	RF12
Módulos	M04, M05, M06, M07, M02
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** O sistema deve implementar Retriever, Gerador, Fonte de conhecimento e Orquestrador.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Arquitetura RAG (componentes obrigatórios)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF12.
4. Sistema registra eventos (`audit_log` / LangSmith).

5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF13 — Recuperação híbrida (denso + esparso)

Campo	Valor
Requisito	RF13
Módulos	M04
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Combinar busca densa (embeddings) e esparsa (BM25) com fusão de resultados.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Recuperação híbrida (denso + esparso)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF13.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF14 — Gerador com modelo de domínio matemático

Campo	Valor
Requisito	RF14
Módulos	M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Utilizar modelo especializado em matemática, não LLM genérico.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Gerador com modelo de domínio matemático».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF14.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF15 — Fontes de conhecimento estruturadas e não estruturadas

Campo	Valor
Requisito	RF15
Módulos	M06, M07, M08
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Suportar PDFs, DOCX, TXT e fontes estruturadas com metadados.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Fontes de conhecimento estruturadas e não estruturadas».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF15.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF16 — Pipeline de ingestão em lote

Campo	Valor
Requisito	RF16
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Carregar e processar documentos em lotes para evitar esgotamento de memória.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Pipeline de ingestão em lote».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF16.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF17 — Limpeza e normalização de texto

Campo	Valor
Requisito	RF17
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Remover ruído, normalizar texto e eliminar duplicados antes da indexação.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Limpeza e normalização de texto».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF17.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF18 — Tratamento multi-formato de documentos

Campo	Valor
Requisito	RF18
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Suportar texto, PDF nativo, DOCX; OCR para PDFs escaneados.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Tratamento multi-formato de documentos».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF18.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF19 — Web controlada (opcional)

Campo	Valor
Requisito	RF19
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Permitir ingestão web apenas de domínios na whitelist, com revisão.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Web controlada (opcional)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).

3. Sistema executa pipeline necessário para RF19.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF20 — Fragmentação (chunking) semântica

Campo	Valor
Requisito	RF20
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Segmentar por frases e parágrafos, preservando blocos matemáticos.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Fragmentação (chunking) semântica».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF20.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF21 — Chunks granulares com parent-document retrieval

Campo	Valor
Requisito	RF21
Módulos	M04, M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Chunks pequenos para busca precisa; contexto expandido do documento pai na geração.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Chunks granulares com parent-document retrieval».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF21.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF22 — Geração de embeddings

Campo	Valor
Requisito	RF22
Módulos	M06, M07
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Incorporar texto com modelo multilíngue compatível com português.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Geração de embeddings».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF22.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF23 — Embeddings em lote

Campo	Valor
Requisito	RF23
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Processar embeddings em batch para eficiência em grande escala.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Embeddings em lote».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF23.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF24 — Banco de dados vetorial

Campo	Valor
Requisito	RF24
Módulos	M07
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Armazenar e consultar vetores com ambientes distintos para teste e produção.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Banco de dados vetorial».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF24.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF25 — Similaridade por cosseno

Campo	Valor
Requisito	RF25
Módulos	M04, M07
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Usar similaridade cosseno na busca densa.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Similaridade por cosseno».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF25.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF26 — Re-ranking pós-recuperação

Campo	Valor
Requisito	RF26
Módulos	M04
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Aplicar re-ranking para melhorar precisão após fusão híbrida.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Re-ranking pós-recuperação».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF26.

4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF27 — Filtragem de conteúdo sensível na indexação

Campo	Valor
Requisito	RF27
Módulos	M06, M09
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Detectar e mascarar dados confidenciais antes da indexação.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Filtragem de conteúdo sensível na indexação».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF27.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF28 — Mitigação de viés

Campo	Valor
Requisito	RF28
Módulos	M02, M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Reduzir respostas tendenciosas ou estereotipadas.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Mitigação de viés».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF28.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF29 — Transparência: citação de fontes

Campo	Valor
Requisito	RF29
Módulos	M02, M01, M10
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Apresentar documentos/chunks usados na geração da resposta.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Transparência: citação de fontes».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF29.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF30 — Privacidade e conformidade LGPD

Campo	Valor
Requisito	RF30
Módulos	M09
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Anonimização, auditoria, consentimento e direitos do titular.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Privacidade e conformidade LGPD».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF30.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF31 — Auditoria via LangSmith

Campo	Valor
Requisito	RF31
Módulos	M09, M02
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Rastrear todas as execuções do pipeline RAG no LangSmith.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Auditoria via LangSmith».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF31.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF32 — Conformidade ECA Digital (Lei 15.211/2025)

Campo	Valor
Requisito	RF32
Módulos	M09, M01
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Atender obrigações para sistemas com acesso provável por menores.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Conformidade ECA Digital (Lei 15.211/2025)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF32.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF33 — Alinhamento BNCC — Matemática Ensino Médio

Campo	Valor
Requisito	RF33
Módulos	M08, M02, M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Respostas e conteúdo indexado alinhados às competências e habilidades EM13MAT.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Alinhamento BNCC — Matemática Ensino Médio».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF33.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF34 — Notação matemática (LaTeX)

Campo	Valor
Requisito	RF34
Módulos	M05, M01, M10
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Suportar fórmulas e símbolos matemáticos na geração e exibição.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Notação matemática (LaTeX)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF34.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF35 — Verificação de respostas (TIR com SymPy)

Campo	Valor
Requisito	RF35
Módulos	M05, M02
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Validar cálculos numéricos e simbólicos com ferramenta externa.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Verificação de respostas (TIR com SymPy)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF35.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF36 — Metadados por documento

Campo	Valor
Requisito	RF36
Módulos	M06, M08
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Cada documento indexado deve ter metadados estruturados.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Metadados por documento».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF36.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF37 — Política de abstinência

Campo	Valor
Requisito	RF37
Módulos	M02, M04
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Não responder quando confiança ou recuperação forem insuficientes.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Política de abstinência».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF37.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF38 — Avaliação contínua da qualidade RAG

Campo	Valor
Requisito	RF38
Módulos	M09, M10
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Conjunto de testes de regressão para qualidade de recuperação e geração.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Avaliação contínua da qualidade RAG».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF38.

4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF39 — Reindexação incremental e versionamento

Campo	Valor
Requisito	RF39
Módulos	M06, M07
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Atualizar índice sem reprocessar corpus inteiro; versionar coleções.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Reindexação incremental e versionamento».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF39.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF40 — Integração WhatsApp Cloud API

Campo	Valor
Requisito	RF40
Módulos	M01
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Comunicação com clientes via WhatsApp Business Cloud API (Meta).

Fluxo principal:

1. Estudante EM envia ação relacionada a «Integração WhatsApp Cloud API».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF40.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF41 — Idempotência de mensagens WhatsApp

Campo	Valor
Requisito	RF41
Módulos	M01
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Evitar processamento duplicado de webhooks.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Idempotência de mensagens WhatsApp».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF41.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF42 — Consentimento e opt-out

Campo	Valor
Requisito	RF42
Módulos	M01, M09
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Fluxo de consentimento LGPD/ECA Digital e cancelamento.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Consentimento e opt-out».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF42.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF43 — Modos pedagógicos (tutor vs avaliação)

Campo	Valor
Requisito	RF43
Módulos	M02, M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Diferenciar explicação passo a passo de entrega direta de gabarito.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Modos pedagógicos (tutor vs avaliação)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF43.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF44 — Dashboard web de controle

Campo	Valor
Requisito	RF44
Módulos	M10
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Painel para gestão do sistema RAG sem sobrecarregar o servidor.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Dashboard web de controle».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF44.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF45 — Tratamento de tabelas e imagens em PDFs

Campo	Valor
Requisito	RF45
Módulos	M06
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Preservar estrutura de tabelas e descrição de figuras para RAG.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Tratamento de tabelas e imagens em PDFs».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).

3. Sistema executa pipeline necessário para RF45.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF46 — Orçamento de tokens para Qwen2.5-Math (4K)

Campo	Valor
Requisito	RF46
Módulos	M02, M03, M04, M05
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Toda montagem de prompt, memória e retrieval deve respeitar a janela de **4.096 tokens** do `Qwen2.5-Math-1.5B-Instruct`.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Orçamento de tokens para Qwen2.5-Math (4K)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF46.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

UC-RF47 — Sistema integralmente auditável (ECA Digital + LGPD)

Campo	Valor
Requisito	RF47
Módulos	M01–M10, M09 (camada transversal)
Atores	Estudante EM, Sistema deepEdu
Pré-condições	Matrícula ECA ativa (`VINCULAR`), consentimento `ACEITO`, acesso liberado.
Descrição	**Descrição:** Todo o projeto deve ser auditável de ponta a ponta: canais, pipeline RAG, administração, consentimento e incidentes. A auditoria é obrigatória por força do ECA Digital (Lei 15.211/2025) e da LGPD, não opcional.

Fluxo principal:

1. Estudante EM envia ação relacionada a «Sistema integralmente auditável (ECA Digital + LGPD)».
2. Sistema valida matrícula, consentimento e auditoria (fail-closed).
3. Sistema executa pipeline necessário para RF47.
4. Sistema registra eventos (`audit_log` / LangSmith).
5. Sistema retorna resultado ao ator ou operador.

Pós-condições | Evento registrado em `audit_log`; resposta entregue via WhatsApp ou painel. |

---

3. Casos de uso não funcionais (RNF)

UC-RNF01 — Stack LangChain, LangGraph e LangSmith

Campo	Valor
Requisito	RNF01
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] LangGraph para orquestração de agentes - [ ] LangSmith para tracing em todos os ambientes não locais - [ ] Versões fixadas e testadas em conjunto

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF01 — Stack LangChain, LangGraph e LangSmith.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF02 — Bancos vetoriais por ambiente

Campo	Valor
Requisito	RNF02
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF02 — Bancos vetoriais por ambiente.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF03 — Sistema operacional

Campo	Valor
Requisito	RNF03
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Ubuntu Server 22.04 LTS ou 24.04 LTS - [ ] Documentação de instalação testada em Ubuntu limpo

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF03 — Sistema operacional.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF04 — API WhatsApp

Campo	Valor
Requisito	RNF04
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] WhatsApp Business Cloud API (Meta) como canal oficial - [ ] Twilio ou BSP alternativo permitido se compatível com Cloud API - [ ] Domínio com TLS válido para webhook

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF04 — API WhatsApp.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF05 — Engenharia de prompt

Campo	Valor
Requisito	RNF05
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Prompts versionados em arquivos, não hardcoded - [ ] Revisão de prompt exige PR e teste de regressão (RF38)

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF05 — Engenharia de prompt.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF06 — Interface web leve

Campo	Valor
Requisito	RNF06
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Frontend estático ou SSR leve (FastAPI + Jinja, ou SPA mínima) - [ ] Não exige GPU no cliente - [ ] Tempo de carregamento inicial < 3s em rede local

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF06 — Interface web leve.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF07 — Containerização Docker modular

Campo	Valor
Requisito	RNF07
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] `docker-compose.yml` com serviços: `api`, `worker`, `qdrant`, `redis`, `dashboard` (opcional) - [ ] Cada serviço com Dockerfile próprio - [ ] Volumes para dados persistentes (índice, uploads, memória) - [ ] Healthche

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF07 — Containerização Docker modular.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF08 — Arquitetura reutilizável (base para outros RAGs)

Campo	Valor
Requisito	RNF08
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Troca de domínio (ex.: Física) alterando: corpus, prompts, metadados — sem reescrever core - [ ] Interfaces `Protocol` ou ABC documentadas em `app/core/interfaces/`

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF08 — Arquitetura reutilizável (base para outros RAGs).

2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF09 — Modelo LLM

Campo	Valor
Requisito	RNF09
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] `Qwen2.5-Math-1.5B-Instruct` como padrão - [ ] Contexto máximo: **4.096 tokens** (série Math; não confundir com Qwen2.5 genérico 128K) - [ ] Requisito mínimo de hardware documentado: 8 GB RAM (CPU) ou 6 GB VRAM (GPU)

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF09 — Modelo LLM.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF10 — Idioma

Campo	Valor
Requisito	RNF10
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Português brasileiro como idioma principal de interface e respostas - [ ] Embeddings multilíngues compatíveis com PT

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF10 — Idioma.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF11 — Desempenho

Campo	Valor
Requisito	RNF11
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] p95 latência end-to-end WhatsApp (mensagem recebida → resposta enviada) < 30s em hardware de referência - [ ] p95 retrieval < 2s - [ ] p95 geração LLM < 20s (1.5B, CPU aceitável com aviso)

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF11 — Desempenho.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.

4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF12 — Observabilidade

Campo	Valor
Requisito	RNF12
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Logs estruturados (JSON) com `correlation_id` - [ ] Métricas Prometheus ou equivalente: `rag_latency`, `retrieval_score`, `abstention_rate` - [ ] Alertas configuráveis para erro > 5% em 5 minutos

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF12 — Observabilidade.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF13 — Segurança

Campo	Valor
Requisito	RNF13
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Segredos em variáveis de ambiente ou vault, nunca em código - [ ] `ADMIN_API_KEY` ou OAuth para endpoints administrativos - [ ] Rate limit por IP e por número WhatsApp - [ ] HTTPS obrigatório em produção

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF13 — Segurança.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF14 — Controle de acesso (RBAC)

Campo	Valor
Requisito	RNF14
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Papéis: `admin`, `operator`, `viewer` - [ ] Matriz de permissões documentada em `docs/RBAC.md`

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF14 — Controle de acesso (RBAC).
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF15 — CI/CD e qualidade

Campo	Valor
Requisito	RNF15
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Pipeline CI: lint, testes unitários, `eval_rag.py` em dataset reduzido - [ ] Regressão de métricas RAG bloqueia merge na branch principal - [ ] Build de imagens Docker em cada release tag

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF15 — CI/CD e qualidade.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF16 — Backup e recuperação

Campo	Valor
Requisito	RNF16
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Backup diário: banco vetorial, metadados, corpus em `data/materials` - [ ] Procedimento de restore documentado e testado trimestralmente - [ ] RPO ≤ 24h; RTO ≤ 4h

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF16 — Backup e recuperação.
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.

4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

UC-RNF17 — Escalabilidade horizontal (fase F3)

Campo	Valor
Requisito	RNF17
Módulos	—
Atores	Sistema deepEdu, Operador, DPO
Pré-condições	Ambiente configurado conforme `.env.example` e documentação de deploy.
Descrição	**Critérios de aceitação:** - [ ] Workers de fila escaláveis (`docker compose up --scale worker=3`) - [ ] API stateless; estado em banco/fila

Fluxo de verificação:

1. Operador/DPO inicia verificação de RNF17 — Escalabilidade horizontal (fase F3).
2. Sistema aplica configuração, limites ou política correspondente.
3. Métricas, logs ou testes automatizados confirmam conformidade.
4. Evidência arquivada (relatório eval, backup, CI).

Pós-condições | Critério de aceitação do requisito verificado em teste ou checklist. |

---

4. Matriz de rastreabilidade UC → RF/RNF

UC	Requisito	Tipo
UC-RF1	RF01	RF
UC-RF2	RF02	RF
UC-RF3	RF03	RF
UC-RF4	RF04	RF
UC-RF5	RF05	RF
UC-RF6	RF06	RF
UC-RF7	RF07	RF
UC-RF8	RF08	RF
UC-RF9	RF09	RF
UC-RF0	RF10	RF
UC-RF1	RF11	RF
UC-RF2	RF12	RF
UC-RF3	RF13	RF
UC-RF4	RF14	RF
UC-RF5	RF15	RF
UC-RF6	RF16	RF
UC-RF7	RF17	RF
UC-RF8	RF18	RF
UC-RF9	RF19	RF
UC-RF0	RF20	RF
UC-RF1	RF21	RF
UC-RF2	RF22	RF
UC-RF3	RF23	RF
UC-RF4	RF24	RF
UC-RF5	RF25	RF
UC-RF6	RF26	RF
UC-RF7	RF27	RF
UC-RF8	RF28	RF
UC-RF9	RF29	RF
UC-RF0	RF30	RF
UC-RF1	RF31	RF
UC-RF2	RF32	RF

UC	Requisito	Tipo
UC-RF3	RF33	RF
UC-RF4	RF34	RF
UC-RF5	RF35	RF
UC-RF6	RF36	RF
UC-RF7	RF37	RF
UC-RF8	RF38	RF
UC-RF9	RF39	RF
UC-RF0	RF40	RF
UC-RF1	RF41	RF
UC-RF2	RF42	RF
UC-RF3	RF43	RF
UC-RF4	RF44	RF
UC-RF5	RF45	RF
UC-RF6	RF46	RF
UC-RF7	RF47	RF
UC-RNF01	RNF01	RNF
UC-RNF02	RNF02	RNF
UC-RNF03	RNF03	RNF
UC-RNF04	RNF04	RNF
UC-RNF05	RNF05	RNF
UC-RNF06	RNF06	RNF
UC-RNF07	RNF07	RNF
UC-RNF08	RNF08	RNF
UC-RNF09	RNF09	RNF
UC-RNF10	RNF10	RNF
UC-RNF11	RNF11	RNF
UC-RNF12	RNF12	RNF
UC-RNF13	RNF13	RNF
UC-RNF14	RNF14	RNF
UC-RNF15	RNF15	RNF
UC-RNF16	RNF16	RNF
UC-RNF17	RNF17	RNF

Parte VI — Checklist ECA Digital

Campo	Valor
Sistema	deepEdu — Tutor RAG de Matemática (Ensino Médio)
Versão	1.0
Data	29/06/2026
Responsável	_____
Instituição	_____

Instruções

Marque cada item conforme o status: **S** = Sim | **N** = Não | **NA** = Não aplicável | **P** = Parcial (descrever em observações).

Itens marcados **N** ou **P** devem ter plano de ação com prazo na coluna de observações.

Referência legal: Lei nº 15.211/2025 (Estatuto Digital da Criança e do Adolescente).

1. Governança e inventário

#	Item	S	N	NA	P	Observações / Plano de ação
1.1	Inventário completo do ecossistema digital (softwares, APIs, fornecedores) documentado	☐	☐	☐	☐	
1.2	Classificação de cada ferramenta pelo critério de “acesso provável” por menores	☐	☐	☐	☐	
1.3	DPIA (Relatório de Impacto à Proteção de Dados) preenchido e aprovado	☐	☐	☐	☐	
1.4	DPO ou encarregado de dados designado e contato publicado	☐	☐	☐	☐	
1.5	Política de privacidade específica para o tutor RAG disponível aos responsáveis	☐	☐	☐	☐	

2. Consentimento e verificação de idade

#	Item	S	N	NA	P	Observações / Plano de ação
2.1	Consentimento parental **granular** (não genérico/guarda-chuva) implementado	☐	☐	☐	☐	
2.2	Registro auditável de consentimento: data, versão dos termos, identificador pseudonimizado	☐	☐	☐	☐	
2.3	Verificação de faixa etária **sem autodeclaração simples** (vínculo escolar/código)	☐	☐	☐	☐	
2.4	Fluxo de recusa de consentimento: sistema não processa dados além de mensagem informativa	☐	☐	☐	☐	
2.5	Mecanismo de opt-out (`SAIR` ou equivalente) funcional e testado	☐	☐	☐	☐	
2.6	Direito de acesso, correção e exclusão de dados implementado	☐	☐	☐	☐	

3. Tratamento de dados

#	Item	S	N	NA	P	Observações / Plano de ação
3.1	Coleta mínima de dados (apenas o necessário para tutoria)	☐	☐	☐	☐	
3.2	Dados pessoais mascarados antes de indexação no RAG (RF27)	☐	☐	☐	☐	
3.3	Histórico de chat com política de retenção definida (padrão: 90 dias)	☐	☐	☐	☐	
3.4	Criptografia em trânsito (HTTPS/ TLS) em todos os endpoints	☐	☐	☐	☐	
3.5	Criptografia em repouso para banco de dados e backups	☐	☐	☐	☐	
3.6	**Proibição** de uso de dados para publicidade ou perfilamento comercial	☐	☐	☐	☐	
3.7	**Proibição** de compartilhamento de dados com terceiros sem base legal	☐	☐	☐	☐	

4. Fornecedores e contratos

#	Item	S	N	NA	P	Observações / Plano de ação
4.1	Due diligence de fornecedores (Meta/ WhatsApp, LangSmith, hospedagem) documentada	☐	☐	☐	☐	
4.2	Cláusulas contratuais: exclusão de dados ao término da relação	☐	☐	☐	☐	
4.3	Cláusulas contratuais: notificação de incidentes em até 24 horas	☐	☐	☐	☐	
4.4	Cláusulas contratuais: direito de auditoria pela instituição de ensino	☐	☐	☐	☐	
4.5	Fornecedores com privacy by design e proteção por padrão comprovados	☐	☐	☐	☐	

5. Segurança e incidentes

#	Item	S	N	NA	P	Observações / Plano de ação
5.1	Protocolo de resposta a incidentes documentado	☐	☐	☐	☐	
5.2	Registro de incidentes com data, impacto, ação corretiva	☐	☐	☐	☐	
5.3	Validação de assinatura webhook WhatsApp (`X-Hub-Signature-256`)	☐	☐	☐	☐	
5.4	Rate limiting e proteção contra abuso	☐	☐	☐	☐	
5.5	Segredos em variáveis de ambiente (nunca em código-fonte)	☐	☐	☐	☐	
5.6	Teste de restauração de backup realizado nos últimos 90 dias	☐	☐	☐	☐	

6. Transparência e auditoria

#	Item	S	N	NA	P	Observações / Plano de ação
6.1	Citação de fontes nas respostas do tutor (RF29)	☐	☐	☐	☐	
6.2	Traces LangSmith ativos em produção (RF31)	☐	☐	☐	☐	
6.3	Logs de auditoria locais (`audit_log`) conforme `docs/AUDITORIA_ECA.md`	☐	☐	☐	☐	
6.4	**Todo o projeto** auditável — todos os módulos emitem eventos (RF47)	☐	☐	☐	☐	
6.5	Fail-closed: sem log, sem processamento de dados de menor	☐	☐	☐	☐	
6.6	Exportação de relatórios para escola/DPO (`export_audit.py`)	☐	☐	☐	☐	
6.7	Comunicação clara ao usuário sobre registro de conversas (ECA)	☐	☐	☐	☐	
6.8	Canal de contato para dúvidas de privacidade disponível	☐	☐	☐	☐	

---

7. Capacitação

#	Item	S	N	NA	P	Observações / Plano de ação
7.1	Equipe técnica treinada em LGPD e ECA Digital	☐	☐	☐	☐	
7.2	Professores/ gestores informados sobre funcionamento e riscos do sistema	☐	☐	☐	☐	
7.3	Material informativo para pais/ responsáveis disponibilizado	☐	☐	☐	☐	

Resultado da auditoria

Métrica	Valor
Total de itens aplicáveis	_____
Itens conformes (S)	_____
Itens não conformes (N)	_____
Itens parciais (P)	_____
Percentual de conformidade	_____%

Parecer: ☐ Aprovado para produção ☐ Aprovado com ressalvas ☐ Reprovado

Assinatura do responsável técnico: _____ Data: //_____

Assinatura do DPO / Encarregado: _____ Data: //_____

Assinatura da gestão escolar: _____ Data: //_____

Parte VII — Controle de Acesso (RBAC)

Campo	Valor
Sistema	deepEdu — Tutor RAG de Matemática (Ensino Médio)
Versão	1.0
Data	29/06/2026

1. Papéis (roles)

Papel	Descrição	Público típico
admin	Acesso total ao sistema, configuração e governança	TI da escola, desenvolvedor
operator	Gestão operacional: corpus, reindexação, monitoramento	Coordenador pedagógico, suporte
viewer	Somente leitura: métricas, logs, visualização de chunks	Professor, gestor

2. Recursos do sistema

ID	Recurso	Descrição
R01	`chat.test`	Interface web de chat de teste
R02	`dashboard.metrics`	Métricas e status dos serviços
R03	`corpus.list`	Listar documentos indexados
R04	`corpus.upload`	Upload de novos materiais
R05	`corpus.delete`	Remover documentos do índice
R06	`corpus.reindex`	Disparar reindexação
R07	`chunks.view`	Visualizar chunks e metadados
R08	`sessions.view`	Visualizar sessões de chat (pseudonimizadas)
R09	`sessions.delete`	Excluir dados de sessão (LGPD)
R10	`config.read`	Ler configurações do sistema
R11	`config.write`	Alterar configurações (prompts, limiares)
R12	`users.manage`	Gerenciar usuários e papéis
R13	`audit.logs`	Acessar logs de auditoria
R14	`langsmith.link`	Acessar traces no LangSmith
R15	`eval.run`	Executar avaliação RAG
R16	`whatsapp.config`	Configurar webhook e templates

---

3. Matriz de permissões

Recurso	admin	operator	viewer
R01 `chat.test`			
R02 `dashboard.metrics`			
R03 `corpus.list`			
R04 `corpus.upload`			
R05 `corpus.delete`			
R06 `corpus.reindex`			
R07 `chunks.view`			
R08 `sessions.view`			
R09 `sessions.delete`			
R10 `config.read`			
R11 `config.write`			
R12 `users.manage`			
R13 `audit.logs`			
R14 `langsmith.link`			
R15 `eval.run`			
R16 `whatsapp.config`			

Legenda: = permitido | = negado

---

4. Autenticação

Canal	Método	Observação
Dashboard web	API Key (`ADMIN_API_KEY`) ou OAuth2	Sessão com timeout de 8h
API interna	Header `Authorization: Bearer <token>`	Tokens com escopo por papel
WhatsApp	Número de telefone + consentimento (RF42)	Não é RBAC administrativo

---

5. Regras adicionais

1. **Princípio do menor privilégio:** usuários recebem o papel mínimo necessário.

2. **Separação de ambientes:** credenciais de produção não funcionam em desenvolvimento.
3. **Revogação:** desativar usuário remove acesso imediatamente (tokens invalidados).
4. **Auditoria:** toda ação em R04–R12, R15, R16 gera log com `user_id`, `action`, `timestamp`.
5. **Dados de menores:** `sessions.view` exibe apenas `session_id` pseudonimizado, nunca nome completo.

---

6. Procedimento de concessão de acesso

1. Solicitação formal à gestão/TI com justificativa e papel desejado.
2. Aprovação do admin ou gestor escolar.
3. Criação de credencial com papel atribuído.
4. Registro em log de auditoria.
5. Revisão trimestral de acessos ativos.

---

7. Registro de usuários (modelo)

user_id	Nome	Papel	Criado em	Último acesso	Status
					ativo/inativo

Parte VIII — Registro de Operações (ROPA)

Campo	Valor
Controlador	_____ (Instituição de Ensino)
Operador	_____ (Responsável técnico / deepEdu)
Encarregado (DPO)	_____
Contato DPO	_____
Versão	1.0
Data	29/06/2026
Revisão prevista	Trimestral

1. Identificação do tratamento

Campo	Descrição
Nome do sistema	deepEdu — Tutor RAG de Matemática para Ensino Médio
Finalidade	Tutoria personalizada em Matemática via WhatsApp, com recuperação de conteúdo curricular indexado
Base legal (LGPD)	Consentimento do responsável legal (Art. 7º, I) + Legítimo interesse educacional com salvaguardas (Art. 7º, IX), em conformidade com ECA Digital
Categorias de titulares	Estudantes do Ensino Médio (15–17 anos), menores de idade
Prazo de retenção	Histórico de chat: 90 dias (configurável). Logs de auditoria: 12 meses. Consentimentos: 5 anos após término da relação.

2. Dados pessoais tratados

Categoria	Dados	Obrigatório	Finalidade
Identificação	Número de telefone (WhatsApp)	Sim	Canal de comunicação e sessão
Identificação	Código escolar / matrícula (hash)	Não	Verificação de vínculo e idade
Conteúdo	Mensagens enviadas pelo estudante	Sim	Processamento RAG e tutoria
Conteúdo	Respostas geradas pelo sistema	Sim	Prestação do serviço
Técnico	session_id, timestamps, message_id	Sim	Funcionamento, auditoria, idempotência
Técnico	IP do webhook (Meta)	Sim	Segurança e logs
Consentimento	Registro de aceite/recusa de termos	Sim	Conformidade LGPD/ECA Digital

Dados sensíveis: O sistema **não deve** coletar dados sensíveis (saúde, origem racial, biometria etc.). Mensagens com conteúdo sensível acidental devem ser mascaradas (RF27).

---

3. Operações de tratamento

#	Operação	Descrição	Base legal
1	Coleta	Recebimento de mensagem via webhook WhatsApp	Consentimento
2	Armazenamento	Persistência de histórico de sessão e consentimento	Consentimento + execução de contrato
3	Processamento	Embedding da pergunta, retrieval, geração LLM	Execução de contrato
4	Compartilhamento	Envio de traces ao LangSmith (pseudonimizado)	Legítimo interesse (auditoria técnica)
5	Compartilhamento	API WhatsApp (Meta) para envio de resposta	Execução de contrato
6	Eliminação	Exclusão por solicitação ou expiração de retenção	Obrigação legal (LGPD Art. 18)
7	Anonimização	Mascaramento de PII antes de indexação no corpus	Legítimo interesse

---

4. Fluxo de dados

```
Estudante (WhatsApp)
    → Meta Cloud API (webhook HTTPS)
    → deepEdu API (validação, fila)
    → Worker (RAG: retrieval + LLM)
    → Banco vetorial (Qdrant) — apenas corpus curricular, sem PII
    → Banco de sessões (PostgreSQL/SQLite) — histórico pseudonimizado
    → LangSmith (traces técnicos)
    → Meta Cloud API (resposta ao estudante)
```

---

5. Compartilhamento com terceiros

Terceiro	Dados compartilhados	Finalidade	País	Garantias
Meta (WhatsApp)	Telefone, mensagens	Entrega de mensagens	EUA	DPA, cláusulas contratuais
LangSmith (LangChain)	Traces pseudonimizados	Auditoria e debugging	EUA	Opt-out de PII nos traces
Provedor de hospedagem	Dados em repouso	Infraestrutura	_____	Contrato + criptografia

Não há compartilhamento para fins publicitários ou perfilamento.

---

6. Medidas de segurança

Medida	Implementação
Criptografia em trânsito	TLS 1.2+ em todos os endpoints
Criptografia em repouso	Volume criptografado / banco com TDE
Controle de acesso	RBAC (ver `docs/RBAC.md`)
Pseudonimização	phone_hash, session_id sem nome
Mascaramento na indexação	RF27 — CPF, e-mail, telefone → `[REDACTED]`
Backup	Diário, criptografado, retenção 30 dias
Teste de restore	Trimestral

---

7. Direitos dos titulares (LGPD Art. 18)

Direito	Como exercer	Prazo de resposta
Confirmação de tratamento	E-mail ao DPO	15 dias
Acesso aos dados	E-mail ao DPO	15 dias
Correção	E-mail ao DPO	15 dias
Eliminação	E-mail ao DPO ou comando `SAIR` no WhatsApp	15 dias
Portabilidade	Exportação JSON sob solicitação	15 dias
Revogação de consentimento	Comando `SAIR` ou e-mail ao DPO	Imediato (cessa tratamento)

---

8. Transferência internacional

Destinatário	Mecanismo	Status
Meta (WhatsApp Cloud API)	Cláusulas contratuais padrão / DPA	☐ Verificado
LangSmith	Avaliar localização de dados / DPA	☐ Verificado

---

9. Avaliação de risco

Risco	Probabilidade	Impacto	Mitigação
Vazamento de histórico de chat	Média	Alto	Criptografia, RBAC, retenção limitada
Resposta incorreta em avaliação	Alta	Médio	Modo tutor (RF43), citação de fontes
Coleta excessiva de dados	Baixa	Alto	Coleta mínima, revisão trimestral ROPA
Acesso não autorizado ao dashboard	Baixa	Alto	RBAC, API Key, HTTPS
Uso indevido por terceiros (webhook)	Baixa	Alto	Validação HMAC, rate limit

---

10. Histórico de revisões

Versão	Data	Responsável	Alteração
1.0	29/06/2026		Versão inicial

Próxima revisão: //_____

Parte IX — DPIA (Avaliação de Impacto)

Campo	Valor
Sistema	deepEdu — Tutor RAG de Matemática EM
Controlador	Instituição de Ensino contratante
Operador técnico	Equipe responsável pelo deepEdu
Versão	1.0
Data	29/06/2026
Base legal	LGPD Art. 38 + ECA Digital (Lei 15.211/2025)

1. Descrição do tratamento

Tutoria automatizada em Matemática via WhatsApp para estudantes de 15–17 anos, com recuperação de conteúdo curricular indexado (RAG), memória de sessão pseudonimizada e auditoria integral.

2. Necessidade e proporcionalidade

Pergunta	Resposta
O tratamento é necessário?	Sim — prestação do serviço educacional contratado
Existe alternativa menos invasiva?	Canal web autenticado; WhatsApp escolhido por acessibilidade
Dados minimizados?	Sim — apenas telefone, mensagens e metadados técnicos
Retenção limitada?	Sim — ver `docs/ROPA.md`

3. Riscos e mitigações

Risco	Impacto	Probabilidade	Mitigação implementada
Vazamento de telefone	Alto	Baixa	`phone_hash` + vault Fernet (`phone_vault`)
Processamento sem consentimento	Alto	Média	Fluxo ECA: enroll → VINCULAR → ACEITO
Falha de auditoria	Alto	Baixa	Fail-closed (`AUDIT_FAIL_CLOSED=true`)
Resposta inadequada a menor	Médio	Média	Abstinência RAG (RF37), prompt pedagógico
Acesso admin indevido	Alto	Baixa	`ADMIN_API_KEY` + RBAC (`docs/RBAC.md`)
Perda de dados	Médio	Baixa	`scripts/backup_data.sh` (RNF16)

---

4. Direitos dos titulares

Direito	Como exercer
Acesso	Solicitar ao DPO da escola
Correção	Atualização cadastral via admin
Eliminação	Comando `SAIR` + procedimento DPO
Portabilidade	Exportação de histórico sob demanda
Revogação	`SAIR` revoga consentimento imediatamente

---

5. Conclusão

O tratamento é **admissível** desde que: (1) consentimento parental documentado; (2) segredos de produção configurados; (3) ROPA e este DPIA assinados pelo controlador e DPO.

Aprovação DPO: _____ Data: //_____

Parte X — Segurança de Dados em Repouso

Campo	Valor
Versão	1.0
Requisitos	RF30, RNF13, RNF16
Data	29/06/2026

1. Camadas de proteção

Camada	Implementação	Status
Aplicação	Telefone criptografado (Fernet) em `phone_vault`	Implementado
Identificadores	`phone_hash` + `session_id` pseudonimizado	Implementado
Banco SQLite	Permissões restritas (`chmod 600`) no volume	Deploy
Volume	LUKS/dm-crypt no servidor Ubuntu	Infraestrutura
Backup	`scripts/backup_data.sh` com retenção configurável	Implementado

2. Configuração recomendada (produção)

```
# Permissões dos bancos
chmod 600 data/audit/audit.db data/chat_history/chat_history.db data/billing/billing.db

# Backup diário (cron)
0 2 * * * /home/USUARIO/Projects/deepEdu/scripts/backup_data.sh >> /var/log/deepedu_backup.log 2

# Criptografia de volume (LUKS) — executar na instalação do servidor
# Ver: https://help.ubuntu.com/community/Full_Disk_Encryption_Howto_2019
```

---

3. Validação em startup

`app/core/startup_checks.py` bloqueia subida em `ENV=production` se: - `AUDIT_PHONE_SALT` < 16 caracteres - `PHONE_ENCRYPTION_KEY` ausente ou placeholder - `ADMIN_API_KEY` fraca - `AUDIT_FAIL_CLOSED` desligado

---

4. Checklist operacional

- ☐ Volume `/data` em LUKS ou disco criptografado na nuvem
- ☐ Backups testados (restauração mensal)
- ☐ Chaves Fernet rotacionadas anualmente
- ☐ Acesso SSH apenas por chave
- ☐ Firewall: portas 80/443 públicas; 8000 apenas localhost

Parte XI — Avaliação RAG

Objetivo

Conjunto de perguntas de referência para medir qualidade do RAG (RF38), executado via `scripts/eval_rag.py`.

Arquivo

- **CSV:** `docs/eval/dataset_rag_matematica_em.csv`
- **Mínimo para produção:** 50 perguntas ativas (`ativo=true`)
- **Atual: 50 perguntas ativas** (EM-001 a EM-050)

Campos

Campo	Tipo	Descrição
`id`	string	Identificador único (ex.: EM-001)
`pergunta`	string	Pergunta do estudante
`serie`	int	1, 2 ou 3 (ano do EM)
`tema`	string	Tema matemático
`habilidade_bncc`	string	Código EM13MATxxx
`resposta_esperada`	string	Resposta ideal para comparação
`fonte_esperada`	string	Nome da fonte citada
`documento_esperado`	string	Arquivo no corpus
`pagina_esperada`	int	Página no documento
`requer_calculo`	bool	Se deve usar SymPy (RF35)
`requer_citacao`	bool	Se resposta deve citar fonte (RF29)
`dificuldade`	string	fácil, média, difícil
`ativo`	bool	Incluir na avaliação
`observacoes`	string	Notas para avaliadores

Métricas alvo

Métrica	Limiar mínimo (F2)	Limiar produção (F3)
precision@5	≥ 0.60	≥ 0.70
faithfulness	≥ 0.70	≥ 0.80
citation_accuracy	≥ 0.65	≥ 0.75
abstention_precision	≥ 0.80	≥ 0.85

Uso

```
python scripts/eval_rag.py --dataset docs/eval/dataset_rag_matematica_em.csv --output reports/ev
```

Regressão > 5% em qualquer métrica bloqueia deploy (RNF15).

Anexo A — Dataset de avaliação RAG (50 perguntas ativas)

Arquivo completo: `docs/eval/dataset_rag_matematica_em.csv` (EM-001 a EM-050).

id	pergunta	serie	tema	habilidade_bncc	resposta_esperada	fonte_esperada	c
EM-001	"O que é uma função do 1º grau?"	1	Álgebra	EM13MAT101	"Função polinomial de grau 1 na forma f(x)=ax+b com a≠0"	"Apostila Funções Cap.1"	"
EM-002	"Como calcular o valor de f(3) se f(x)=2x+5?"	1	Álgebra	EM13MAT101	"f(3)=2·3+5=11"	"Apostila Funções Cap.1"	"
EM-003	"Qual a diferença entre progressão aritmética e geométrica?"	2	Sequências	EM13MAT309	"PA tem razão constante entre termos consecutivos (soma); PG tem razão multiplicativa constante"	"Material Sequências"	"
EM-004	"Como encontrar a equação da reta que passa por (2	3) e (4	7)?"	2	Geometria Analítica	EM13MAT401	" a (y
EM-005	"O que é seno de 30 graus?"	2	Trigonometria	EM13MAT305	"sen(30°)=1/2"	"Tabela trigonométrica / Apostila Trigonometria"	"
EM-006	"Explique o teorema de Pitágoras com um exemplo."	1	Geometria	EM13MAT201	"Em triângulo retângulo: a²+b²=c². Ex: catetos 3 e 4 → hipotenusa 5"	"Apostila Geometria Plana"	"
EM-007	"Como calcular a média de 7	8	9 e 10?"	1	Estatística	EM13MAT501	" 4
EM-008	"O que é logaritmo?"	3	Álgebra	EM13MAT102	"Logaritmo é o expoente ao qual a base deve ser elevada para obter um número dado: log_b(a)=c ⟺ b^c=a"	"Apostila Logaritmos"	"
EM-009	"Como resolver x²-5x+6=0?"	2	Álgebra	EM13MAT103	"Fatorando: (x-2)(x-3)=0 → x=2 ou x=3. Ou fórmula de Bhaskara"	"Apostila Equações"	"
EM-010	"O que é probabilidade clássica?"	2	Probabilidade	EM13MAT504	"P(A)=casos favoráveis/casos possíveis	quando todos são igualmente prováveis"	" P

Anexo B — Prompts do sistema

Arquivos em `prompts/`. Orçamento: sistema ≤ 400 tokens (Qwen2.5-Math).

v1_avaliacao_em.md

```
# Tutor de Matemática — Modo Avaliação (v1)
# Orçamento: máx. 300 tokens

Você é um assistente de estudo de Matemática para o Ensino Médio.

## Regras (modo avaliação)
- NÃO resolva exercícios de prova ou listas avaliativas.
- Indique o tema, a habilidade BNCC e onde o aluno pode revisar no material.
- Responda em português brasileiro, de forma breve (máx. 3 parágrafos).
- Use apenas o contexto em ``. Sem contexto, oriente a consultar o professor.

## Resposta tipo
"Esse exercício envolve [tema]. Revise [conceito] na fonte [título], p.[página]. Tente começar p
```

v1_tutor_em.md

```
# Tutor de Matemática — Ensino Médio (v1)
# Orçamento: máx. 400 tokens (contar com tokenizer Qwen2.5-Math)
# Arquivo: prompts/v1_tutor_em.md

Você é um tutor de Matemática para estudantes do Ensino Médio brasileiro (15–17 anos).

## Regras
- Responda sempre em português brasileiro, tom acolhedor e claro.
- Explique em passos numerados; não pule etapas.
- Use LaTeX para fórmulas: inline `$...$` ou bloco `$$...$$`.
- Baseie-se APENAS no contexto fornecido entre tags ``. Se não houver informação suficiente, dig
- Cite a fonte ao final: "Fonte: [título], p.[página]".
- Não invente teoremas, fórmulas ou resultados numéricos.
- Para cálculos, indique o procedimento; valores exatos serão verificados pelo sistema.
- Respostas objetivas: prefira até 5 passos e conclusão breve (economia de tokens).
- Se a pergunta parecer de prova em andamento, dê pistas sem entregar o gabarito final.
- Não diga que a conversa é anônima ou não registrada: interações são tratadas conforme a políti

## Modo
- Tutor (padrão): scaffolding e explicação guiada.
- Se modo=avaliacao: apenas indique onde buscar no material, sem resolver.

## Contexto BNCC
Quando pertinente, mencione a habilidade EM13MAT relacionada.

## Formato da resposta
1. Breve contextualização (1–2 frases)
2. Passos da resolução ou explicação
3. Conclusão
4. Fonte citada
```

Termo de aprovação

Declaro ter revisado o presente documento e aprovo seu uso como base para o desenvolvimento do sistema deepEdu.

_____

Product Owner — Nome / Data

_____

Tech Lead — Nome / Data

_____

Responsável pedagógico — Nome / Data

_____

DPO / Encarregado de dados — Nome / Data